

Chương 1 đã trình bày bối cảnh, mục tiêu và phạm vi tổng quát của đề tài. Từ cơ sở đó, chương này tập trung phân tích rõ ngữ cảnh nghiên cứu, các hướng tiếp cận liên quan và những kiến thức nền cần thiết cho đề án. Mục tiêu của chương là làm rõ bài toán đang được giải quyết, chỉ ra khoảng trống của các nghiên cứu hoặc hệ thống gần với đề tài, đồng thời cung cấp nền tảng lý thuyết vừa đủ để hiểu các quyết định thiết kế ở các chương sau.

Nội dung chương được tổ chức thành bốn phần. Phần đầu trình bày phạm vi nghiên cứu và ngữ cảnh bài toán. Phần thứ hai khảo sát các hướng tiếp cận liên quan dưới góc nhìn ưu điểm, hạn chế và mức độ phù hợp với dữ liệu SGK. Hai phần tiếp theo tập trung vào các kiến thức nền có liên hệ trực tiếp đến đề án, gồm RAG cho hỏi đáp dựa trên tài liệu và các kỹ thuật retrieval, reranking cùng phương pháp đánh giá.

0.1 Phạm vi nghiên cứu

Chatbot giáo dục trong phạm vi đề án này được hiểu là một hệ thống hỗ trợ người học và giáo viên tương tác với tri thức môn Tin học THPT bằng ngôn ngữ tự nhiên. Khác với chatbot hội thoại thông thường, hệ thống cần trả lời dựa trên nội dung sách giáo khoa, đồng thời cần tôn trọng phạm vi lớp học, bộ sách và chủ đề mà người dùng đang quan tâm.

Dữ liệu của đề tài gồm SGK Tin học THPT lớp 10, 11 và 12 thuộc hai bộ Cánh Diều và Kết Nối Tri Thức. Các tài liệu này có cấu trúc phân cấp theo bộ sách, lớp, chủ đề, bài học và mục nội dung. Đặc điểm phân cấp này tạo ra lợi thế khi truy xuất theo phạm vi, nhưng cũng đặt ra yêu cầu hệ thống phải quản lý metadata chính xác. Nếu metadata bị bỏ qua, câu trả lời có thể trộn nội dung giữa hai bộ sách hoặc giữa các lớp khác nhau.

Với người học, nhu cầu chính là đặt câu hỏi tự nhiên, yêu cầu giải thích khái niệm, ôn lại nội dung bài học hoặc luyện tập theo chủ đề. Với giáo viên, hệ thống có thể hỗ trợ chuẩn bị câu hỏi, dàn ý slide hoặc giáo án. Tuy nhiên, các tác vụ này đều phụ thuộc vào một nền tảng chung: hệ thống phải truy xuất đúng ngữ cảnh từ SGK trước khi sinh nội dung.

Hệ thống hỏi đáp có thể được chia thành hai nhóm chính: closed-book question answering và open-book question answering. Trong closed-book question answering, mô hình trả lời chủ yếu dựa trên tri thức đã học trong quá trình huấn luyện. Trong open-book hoặc document-grounded question answering, hệ thống được cung cấp thêm tài liệu nguồn và phải dựa vào tài liệu đó để trả lời.

Đề tài này thuộc nhóm document-grounded question answering. Câu trả lời

không nên chỉ dựa vào tri thức tham số của mô hình ngôn ngữ, vì tri thức đó có thể không khớp với chương trình SGK Việt Nam hoặc không phản ánh đúng phạm vi sách người dùng đang học. Thay vào đó, hệ thống cần tìm các đoạn tài liệu liên quan trong SGK, sau đó dùng chúng làm ngữ cảnh để sinh câu trả lời.

Một pipeline hỏi đáp dựa trên tài liệu thường gồm các bước chính: tiếp nhận câu hỏi, xác định phạm vi hoặc ý định, truy xuất tài liệu liên quan, xây dựng ngữ cảnh, sinh câu trả lời và kiểm tra kết quả. Trong pipeline này, bước truy xuất đóng vai trò đặc biệt quan trọng. Nếu hệ thống truy xuất sai hoặc thiếu ngữ cảnh, mô hình sinh câu trả lời khó có thể tạo ra kết quả đúng, dù prompt được thiết kế tốt.

0.2 Các nghiên cứu liên quan

Các nghiên cứu và giải pháp gần với đề tài hiện nay có thể được nhìn theo cả góc độ học thuật lẫn góc độ sản phẩm. Trong phạm vi bài toán hỗ trợ học tập môn Tin học THPT theo chương trình GDPT 2018, ba nhóm đối tượng đáng chú ý nhất gồm các mô hình ngôn ngữ lớn đa mục đích, các chatbot dịch vụ trong nước và các hệ thống học tập hoặc đồ án nghiên cứu đi trước.

0.2.1 Nhóm mô hình ngôn ngữ lớn đa mục đích

Nhóm này bao gồm các nền tảng như ChatGPT, Gemini và Claude. Ưu điểm lớn nhất của chúng là khả năng hội thoại tự nhiên, suy luận linh hoạt và hỗ trợ tốt các câu hỏi liên quan đến mã nguồn. Với các bài toán như giải thích một đoạn chương trình hoặc gợi ý thuật toán tổng quát, các mô hình này thường cho chất lượng phản hồi cao.

Tuy nhiên, hạn chế quan trọng khi áp dụng trực tiếp vào giáo dục phổ thông Việt Nam là thiếu ngữ cảnh cục bộ. Do được huấn luyện trên dữ liệu toàn cầu, các mô hình này không tự nhận biết được ranh giới kiến thức theo lớp học, bộ sách và định hướng môn học trong chương trình GDPT 2018. Khi học sinh hỏi một khái niệm cơ bản, hệ thống có thể trả lời bằng nội dung vượt cấp hoặc theo quy chuẩn ngoài phạm vi SGK. Ngoài ra, các nội dung mang tính đặc thù của chương trình Tin học Việt Nam, như cách diễn giải lý thuyết, định nghĩa trong SGK hoặc các chủ đề về đạo đức số và pháp luật trong môi trường số, có nguy cơ bị trả lời lệch khỏi yêu cầu sư phạm.

0.2.2 Nhóm chatbot dịch vụ và quản trị trong nước

Nhóm này có thể đại diện bởi các nền tảng chatbot do doanh nghiệp trong nước phát triển, chẳng hạn các giải pháp của FPT hoặc VNPT. Điểm mạnh của nhóm này là tính ổn định, khả năng tích hợp vào hệ thống tổ chức và mức độ tối ưu hóa cho tiếng Việt. Các hệ thống như vậy thường phù hợp với những bài toán tư vấn

dịch vụ, tự động hóa quy trình hành chính hoặc hỗ trợ tra cứu thông tin có cấu trúc.

Tuy nhiên, khi xét dưới góc độ hỗ trợ học tập học thuật, các chatbot dịch vụ này chưa phải là lời giải phù hợp. Chúng thường không có module phân tích mã nguồn, không có cơ chế truy xuất tri thức học liệu theo bài học, và cũng không được thiết kế để hướng dẫn người học theo từng bước tư duy. Do đó, dù có lợi thế về hạ tầng và tiếng Việt, nhóm giải pháp này chưa đáp ứng trực tiếp yêu cầu của một trợ lý học tập cho môn Tin học THPT.

0.2.3 Nhóm các hệ thống nghiên cứu và đồ án đi trước

Trong môi trường học thuật, đã có những hệ thống thử nghiệm hỗ trợ học tập bằng chatbot hoặc hỏi đáp tự động. Ưu điểm của nhóm này là tiếp cận gần hơn với đối tượng người dùng cuối và thường bám vào giáo trình hoặc dữ liệu nội địa. Một số hệ thống cũng đã bắt đầu khai thác mô hình ngôn ngữ lớn để sinh dữ liệu hoặc sinh phản hồi.

Dù vậy, nhiều hệ thống đi trước vẫn dựa mạnh vào kiến trúc rule-based hoặc intent classification kết hợp với cơ sở dữ liệu quan hệ truyền thống. Cách làm này dễ kiểm soát nhưng kém linh hoạt khi học sinh dùng từ đồng nghĩa, thay đổi cấu trúc câu hoặc hỏi lệch khỏi bộ kịch bản đã xây dựng. Với các hệ thống có dùng LLM, không ít trường hợp chỉ dừng ở mức gọi API trực tiếp và thiết kế prompt thủ công, nhưng chưa có cơ chế retrieval chuẩn hóa từ học liệu nguồn. Hạn chế của hướng này là chi phí API cao, phản hồi thiếu ổn định và nguy cơ câu trả lời trôi khỏi mạch kiến thức SGK.

Bảng 1: So sánh các nhóm giải pháp cho bài toán chatbot giáo dục

Nhóm giải pháp	Hiểu câu hỏi tự nhiên	Dùng dữ liệu SGK riêng	Khả năng giảm hallucination
Rule-based	Thấp	Có, nhưng khó mở rộng	Cao nếu luật đầy đủ
FAQ/keyword search	Thấp-Trung bình	Có	Trung bình
Semantic search	Trung bình	Có	Phụ thuộc tài liệu trả về
LLM trực tiếp	Cao	Thấp nếu không nạp context	Thấp-Trung bình
RAG	Cao	Cao	Cao hơn nếu retrieval tốt
Adaptive RAG	Cao	Cao	Cao hơn nhờ chọn chiến lược theo câu hỏi

Nhìn từ bảng so sánh, các mô hình LLM đa mục đích có ưu thế rõ rệt về năng lực diễn giải và xử lý mã nguồn, nhưng thiếu kiểm soát theo phạm vi SGK. Các chatbot doanh nghiệp trong nước mạnh về hạ tầng và xử lý tiếng Việt, nhưng không được thiết kế cho bài toán gia sư học thuật. Các hệ thống nghiên cứu đi trước tiếp cận gần hơn với bối cảnh giáo dục, song nhiều hệ thống vẫn còn cứng nhắc hoặc chưa có cơ chế retrieval đủ chặt để neo câu trả lời vào học liệu chuẩn.

Từ đó có thể thấy khoảng trống nghiên cứu của đề tài nằm ở ba điểm. Thứ nhất, cần một hệ thống vừa tận dụng được khả năng diễn giải của LLM, vừa kiểm soát được tri thức theo phạm vi SGK. Thứ hai, hệ thống cần hỗ trợ truy xuất theo lớp, bộ sách và chủ đề thay vì trả lời theo tri thức toàn cục. Thứ ba, chất lượng của hệ thống cần được đánh giá theo từng node, đặc biệt là retrieval và generation, thay vì chỉ nhìn vào câu trả lời cuối cùng. Đây chính là động lực để đề án lựa chọn hướng RAG có xét phạm vi dữ liệu, có khả năng thử nhiều cấu hình search và có benchmark đánh giá riêng cho retrieval.

0.3 Kiến thức nền tảng về RAG cho hỏi đáp dựa trên tài liệu

Mô hình ngôn ngữ lớn là thành phần có khả năng sinh văn bản tự nhiên, giải thích khái niệm và chuyển đổi yêu cầu của người dùng thành đầu ra có cấu trúc. Cơ chế sinh của LLM dựa trên việc dự đoán token tiếp theo theo ngữ cảnh đã có:

$$P(w_1, w_2, \dots, w_T) = \prod_{t=1}^T P(w_t \mid w_1, \dots, w_{t-1}) \quad (1)$$

Trong đó, w_t là token tại vị trí t . Cơ chế này giúp LLM tạo câu trả lời mạch lạc về mặt ngôn ngữ, nhưng không bảo đảm rằng mọi thông tin được sinh ra đều có căn cứ trong tài liệu đang xét.

Khi dùng trực tiếp LLM cho bài toán giáo dục, có một số hạn chế chính. Thứ nhất, mô hình có thể không biết hoặc không ưu tiên đúng nội dung trong SGK Tin học Việt Nam. Thứ hai, mô hình có thể trả lời bằng tri thức ngoài phạm vi bài học, dẫn đến câu trả lời không phù hợp với chương trình. Thứ ba, hiện tượng hallucination có thể làm hệ thống sinh thông tin nghe hợp lý nhưng không tồn tại trong tài liệu. Thứ tư, context window của mô hình có giới hạn, nên không thể đưa toàn bộ SGK vào prompt cho mọi câu hỏi.

Vì các lý do trên, LLM trong đề án không được sử dụng như nguồn tri thức duy nhất. Mô hình được đặt sau lớp truy xuất, nhận ngữ cảnh từ SGK và sinh câu trả lời dựa trên ngữ cảnh đó. Cách tổ chức này giúp giảm phụ thuộc vào tri thức tham số của mô hình và tạo điều kiện để đánh giá lỗi theo từng thành phần.

Embedding là kỹ thuật biểu diễn văn bản thành vector số trong không gian nhiều chiều. Khi hai đoạn văn có ý nghĩa gần nhau, vector của chúng thường có độ tương đồng cao. Trong hệ thống hỏi đáp dựa trên tài liệu, embedding cho phép ánh xạ câu hỏi của người dùng và các đoạn SGK vào cùng một không gian, từ đó tìm các đoạn tài liệu gần nhất về mặt ngữ nghĩa.

Một độ đo phổ biến cho tìm kiếm ngữ nghĩa là cosine similarity:

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} \quad (2)$$

Trong đó, $\mathbf{A}$ và $\mathbf{B}$ là hai vector biểu diễn văn bản. Giá trị càng gần 1 thì hai vector càng cùng hướng, tức nội dung văn bản càng gần nhau về mặt ngữ nghĩa.

Tìm kiếm ngữ nghĩa phù hợp với các câu hỏi được diễn đạt khác với tài liệu gốc nhưng vẫn có cùng ý nghĩa. Tuy nhiên, nó không phải lúc nào cũng xử lý tốt các thuật ngữ chính xác, tên lệnh, ký hiệu hoặc cụm từ hiếm. Vì vậy, trong các hệ thống RAG thực tế, tìm kiếm vector thường được kết hợp với các chiến lược khác như lọc metadata, tìm kiếm từ khóa hoặc reranking.

0.4 Sinh tăng cường truy xuất

Retrieval-Augmented Generation là kiến trúc kết hợp truy xuất thông tin và sinh văn bản. Thay vì để LLM trả lời trực tiếp, hệ thống trước hết truy xuất các đoạn tài liệu liên quan, sau đó đưa các đoạn này vào prompt để LLM sinh câu trả lời dựa trên tài liệu.

Một hệ thống RAG thường gồm hai pha. Pha chuẩn bị dữ liệu thực hiện làm sạch tài liệu, chia tài liệu thành chunk, tạo embedding và lưu chỉ mục cùng metadata. Pha truy vấn nhận câu hỏi người dùng, truy xuất các chunk liên quan, có thể rerank kết quả, xây dựng context và gọi LLM để sinh câu trả lời.

Trong bài toán giáo dục, RAG có ba lợi ích chính. Thứ nhất, hệ thống có thể cập nhật tri thức bằng cách cập nhật kho tài liệu thay vì huấn luyện lại mô hình. Thứ hai, câu trả lời có căn cứ hơn vì được sinh từ context cụ thể. Thứ ba, hệ thống có thể ghi lại context đã dùng để phục vụ kiểm tra, phân tích lỗi và đánh giá thực nghiệm.

Tuy nhiên, RAG không tự động bảo đảm câu trả lời đúng. Nếu chunking làm mất ngữ cảnh, retriever lấy sai đoạn, hoặc context đưa vào prompt chứa nhiều nhiễu, chất lượng câu trả lời vẫn có thể thấp. Vì vậy, đánh giá một hệ thống RAG cần tách riêng chất lượng truy xuất và chất lượng sinh câu trả lời.

0.5 Kiến thức nền tảng về truy xuất, xếp hạng lại và đánh giá

0.5.1 Lọc metadata theo phạm vi

Dữ liệu SGK có metadata tự nhiên như bộ sách, lớp, chủ đề và bài học. Khi người dùng đã nêu rõ phạm vi, ví dụ “lớp 11 Cánh Diều”, hệ thống nên giới hạn truy xuất trong phạm vi đó. Cách làm này giúp giảm nguy cơ lấy nhầm nội dung cùng thuật ngữ nhưng thuộc lớp hoặc bộ sách khác.

Tuy nhiên, lọc quá chặt cũng có thể gây mất kết quả nếu metadata thiếu hoặc câu hỏi không khớp chính xác với chủ đề. Do đó, hệ thống cần ghi nhận phạm vi yêu cầu, phạm vi thực tế đã truy xuất và các trường hợp phải mở rộng phạm vi khi không tìm được context phù hợp.

0.5.2 Viết lại truy vấn và truy xuất đa truy vấn

Câu hỏi của người dùng thường ngắn, mơ hồ hoặc phụ thuộc vào lịch sử hội thoại. Query rewriting là bước viết lại câu hỏi thành dạng rõ hơn để phục vụ truy xuất. Multi-query retrieval mở rộng ý tưởng này bằng cách sinh nhiều truy vấn phụ, sau đó truy xuất và hợp nhất kết quả.

Trong đề án, LLM có thể được dùng để hỗ trợ tạo truy vấn giàu ngữ nghĩa hơn. Tuy nhiên, các truy vấn này chỉ phục vụ retrieval, không được xem là câu trả lời cuối cùng. Hiệu quả của query rewriting cần được kiểm tra bằng benchmark retrieval, thông qua việc so sánh kết quả trước và sau khi viết lại truy vấn.

0.5.3 Xếp hạng lại

Retriever ban đầu thường ưu tiên tốc độ và độ phủ, nên danh sách top-k có thể chứa các đoạn chưa thật sự liên quan. Reranking là bước đánh giá lại các candidate bằng một mô hình chính xác hơn, thường là cross-encoder, để đưa các đoạn phù hợp lên vị trí cao hơn.

Reranking có thể cải thiện chất lượng context đưa vào LLM, nhưng làm tăng chi phí tính toán và độ trễ. Vì vậy, trong thực nghiệm cần so sánh kết quả retrieval trước và sau reranking để xác định lợi ích thực tế của bước này.

0.5.4 Truy xuất thích nghi

Một chiến lược truy xuất cố định không phù hợp với mọi câu hỏi. Câu hỏi định nghĩa cần đoạn nội dung chi tiết, câu hỏi về chương trình học cần metadata, còn câu hỏi tổng quan có thể cần nhiều đoạn đại diện. Adaptive retrieval là hướng chọn chiến lược truy xuất theo loại câu hỏi, phạm vi và tín hiệu ngữ cảnh.

Trong đề án, adaptive retrieval được xem là hướng giải pháp phù hợp vì dữ liệu SGK có cấu trúc phân cấp rõ ràng và người dùng có thể hỏi theo nhiều mức độ chi

tiết khác nhau. Cơ chế này cũng tạo cơ sở để so sánh nhiều cấu hình retrieval trong chương thực nghiệm.

Đánh giá hệ thống RAG cần tách hai câu hỏi: hệ thống có truy xuất đúng context không, và LLM có sinh câu trả lời tốt từ context đó không. Nếu chỉ nhìn câu trả lời cuối cùng, rất khó xác định lỗi đến từ retriever hay từ generator.

Đối với retrieval, một kết quả được xem là đúng khi các context được truy xuất chứa thông tin cần thiết để trả lời câu hỏi. Các thước đo thường dùng gồm Hit@k, Recall@k, Precision@k, MRR và nDCG nếu có nhãn mức độ liên quan. Các thước đo này có thể tính tự động nếu benchmark có expected context, expected source hoặc expected keywords đủ rõ.

Đối với generation, việc đánh giá khó tự động hóa hơn vì câu trả lời có thể đúng theo nhiều cách diễn đạt khác nhau. Trong phạm vi đồ án, chất lượng generation nên được đánh giá thủ công bằng rubric. Các tiêu chí chính gồm độ đúng nội dung, độ đầy đủ, mức độ bám context, độ rõ ràng và khả năng tránh hallucination. LLM có thể được dùng để sinh benchmark ban đầu, nhưng không được dùng làm bộ chấm chính cho generation trong giai đoạn này để tránh tăng chi phí và tránh trùng vai trò với node validate trong pipeline.

0.6 Kết chương

Chương này đã làm rõ phạm vi nghiên cứu của đồ án, bao gồm ngữ cảnh dữ liệu SGK, đối tượng sử dụng và bản chất của bài toán hỏi đáp dựa trên tài liệu. Bên cạnh đó, chương cũng đã khảo sát các hướng tiếp cận liên quan và chỉ ra rằng các giải pháp dựa trên RAG phù hợp hơn với yêu cầu bám sát SGK so với việc dùng trực tiếp mô hình ngôn ngữ lớn.

Hai nhóm kiến thức nền được trình bày trong chương, gồm RAG cho hỏi đáp dựa trên tài liệu và các kỹ thuật retrieval, reranking cùng phương pháp đánh giá, tạo cơ sở trực tiếp cho việc thiết kế giải pháp ở chương tiếp theo. Trên nền tảng đó, Chương 3 sẽ trình bày chi tiết kiến trúc đề xuất, vai trò của từng node và phương pháp đánh giá các thành phần trọng tâm của hệ thống.