

Chương 3 đã trình bày các nền tảng công nghệ được sử dụng trong đồ án, bao gồm mô hình ngôn ngữ lớn, truy xuất tăng cường sinh, biểu diễn vector và kiến trúc đa tác tử. Trên cơ sở đó, Chương 4 mô tả hiện trạng triển khai của hệ thống và các kết quả thực nghiệm đã thu được. Nội dung chương tập trung vào môi trường thực nghiệm, kiến trúc xử lý yêu cầu, các lớp chức năng chính, quy trình đa tác tử cho slide và giáo án, cơ chế truy xuất tri thức, hậu kiểm chất lượng, quản lý phiên, và kết quả đánh giá RAGAS.

Mục tiêu của chương này là làm rõ hệ thống đã được hiện thực hóa như thế nào so với định hướng thiết kế. Các sơ đồ trong chương được trình bày theo từng lớp xử lý để thể hiện vai trò của mỗi khối trong vòng đời yêu cầu, đồng thời phân biệt rõ bộ điều phối cấp hệ thống, các dịch vụ nghiệp vụ, quy trình đa tác tử nội bộ và lớp truy xuất tri thức.

0.1 Môi trường và dữ liệu thực nghiệm

0.1.1 Môi trường phát triển

Hệ thống được xây dựng chủ yếu bằng ngôn ngữ lập trình Python, kết hợp với các thư viện xử lý số như Numpy và Pandas để thao tác trên ma trận vector nhúng. Phần điều phối tổng thể được thiết kế theo hướng bộ điều khiển luồng mỏng; các quyết định định tuyến chính được giữ ở tầng mã nguồn để giảm độ trễ, hỗ trợ gỡ lỗi và thuận lợi cho việc theo vết. LangGraph không được sử dụng như nền tảng bao trùm toàn bộ hệ thống, mà được dùng tập trung cho bộ điều phối sinh học liệu dài, phục vụ hai tác vụ sinh slide và giáo án.


Việc sinh ngôn ngữ tự nhiên được thực hiện thông qua API Google Gemini với mô hình `gemini-2.5-flash-lite` qua thư viện `google-genai`. Đối với truy xuất ngữ nghĩa, hệ thống sử dụng mô hình nhúng `dangvantuan/vietnamese-document-embedding`, tạo vector 768 chiều cho mỗi khối dữ liệu. Giai đoạn tái xếp hạng ở cuối quy trình truy xuất được đảm nhiệm bởi mô hình Cross-Encoder `AITeamVN/Vietnamese_Reranker`. Ngoài truy xuất ngữ nghĩa, hệ thống tự xây dựng thành phần tìm kiếm từ khóa bằng Custom BM25 và hợp nhất kết quả với semantic search thông qua Reciprocal Rank Fusion (RRF).

0.1.2 Dữ liệu thực nghiệm

Nguồn dữ liệu gốc được khai thác từ toàn bộ tài liệu Sách Giáo Khoa Tin học lớp 10, 11 và 12, thuộc hai bộ sách Cánh Diều và Kết Nối Tri Thức. Qua quá trình tiền xử lý, văn bản được làm sạch và dán nhãn phân cấp từ chủ đề, bài học đến tiểu mục. Tổng cộng, dữ liệu được phân rã thành 2348 khối dữ liệu, mỗi khối có thông tin mô tả như bộ sách, lớp, chủ đề, tên bài, kiểu nội dung và cấp phân cấp. Cấu trúc này phục vụ trực tiếp cho truy xuất phân cấp (Hierarchical RAG) và các tác vụ sinh

0.2 Tổng quan kiến trúc toàn bộ hệ thống

Sơ đồ tổng quan tại Hình 0.1 thể hiện vòng đời xử lý chính của một yêu cầu trong hệ thống.



Hình 0.1: Sơ đồ tổng quan kiến trúc hệ thống theo vòng đời xử lý yêu cầu


Trong kiến trúc này, bộ điều phối không đóng vai một agent tự trị toàn phần. Nó

chỉ giữ trạng thái xử lý của yêu cầu, gọi mô hình ngôn ngữ ở các vị trí thật sự cần suy luận ngôn ngữ, và sử dụng mã nguồn xác định cho các bước lập kế hoạch, định tuyến, lưu phiên và ghi vết. Nhờ vậy, hệ thống vừa hỗ trợ nhiều ý định trong một yêu cầu, vừa tránh việc tạo thêm nhiều lượt gọi mô hình không cần thiết ở các bước có thể quyết định bằng logic.

0.3 Thiết kế chi tiết các thành phần hệ thống

0.3.1 Thiết kế Lớp Ngữ cảnh và Ý định (Context & Intent Layer)

Đầu vào của hệ thống gồm câu hỏi gốc, thông tin người dùng, bộ sách/lớp được chọn từ giao diện, lịch sử phiên, các truy vấn phục vụ truy xuất tri thức và thông tin hỗ trợ theo vết. Lớp Ngữ cảnh và Ý định có nhiệm vụ làm rõ yêu cầu hiện tại trước khi hệ thống lập kế hoạch hành động.



Hình 0.2: Chi tiết cấu trúc và luồng xử lý tại Lớp Ngữ cảnh và Ý định

ContextAnalyzer được triển khai bằng logic mã nguồn để đánh giá câu hỏi hiện tại có phụ thuộc vào lịch sử hội thoại hay không. Khi cần, hệ thống trích xuất các


lượt hội thoại gần và liên quan để bổ sung vào câu hỏi hiện tại.

QueryRewriter chỉ được gọi khi cần làm giàu truy vấn cho RAG. Thành phần này có thể tạo nhiều truy vấn ngữ nghĩa từ cùng một câu hỏi, giúp retrieval bao phủ tốt hơn những câu hỏi thiếu ngữ cảnh.

Bộ nhận diện ý định là lời gọi LLM quan trọng ở đầu quy trình. Thành phần này phân tích đồng thời nhiều ý định trong một câu hỏi và trả về danh sách ý định gồm loại yêu cầu chính, chủ đề, lớp, bộ sách và thứ tự xử lý. Giới hạn tối đa 3 ý định được dùng để tránh mở rộng trạng thái quá mức khi người dùng nhập một yêu cầu phức hợp.

0.3.2 Thiết kế Lớp Lập kế hoạch (Planning Layer)

Sau khi có danh sách ý định, hệ thống chuyển sang tầng lập kế hoạch hoàn toàn bằng luật. Tầng này quản lý phiên học và lập kế hoạch hành động; không sử dụng thêm LLM để quyết định hành động.




Hình 0.3: Chu trình lập kế hoạch hành động bằng rule-based logic

SessionManager kiểm tra phiên tương ứng với người dùng và chủ đề hiện tại. Thành phần này quyết định nên tiếp tục phiên đang có, khôi phục từ bộ nhớ phiên, hay tạo phiên mới.

Bộ lập kế hoạch ánh xạ mỗi ý định sang một hành động cụ thể. Các hành động chính bao gồm sinh quiz, sinh slide, sinh giáo án, chấm đáp án, ôn câu sai, thống kê tiến độ, giải thích khái niệm và chat. Khi nhiều ý định liên tiếp tạo ra cùng một hành động, bộ lập kế hoạch loại bỏ trùng lặp để tránh thực thi dư thừa.

0.3.3 Thiết kế Lớp Thực thi (Execution Layer)

Lớp Thực thi nhận danh sách hành động và xử lý theo vòng lặp đa tác vụ. Ở mỗi vòng, bộ điều phối chọn tác vụ đang chạy, sau đó chuyển quyền thực thi cho bộ định tuyến thực thi. Bộ định tuyến dùng danh mục nội bộ để gọi đúng dịch vụ hoặc bộ xử lý.



Hình 0.4: Sơ đồ vòng lặp đa tác vụ và điều phối dịch vụ nghiệp vụ


Dịch vụ quiz sở hữu toàn bộ vòng đời quiz độc lập: sinh câu hỏi, hậu kiểm chất lượng, chấm đáp án, giải thích câu hỏi, ôn câu sai, thống kê và cập nhật tiến độ học tập. Vì luồng này có nhiều trạng thái tương tác như lướt làm quiz và bản ghi từng câu hỏi, nó được giữ ở dạng dịch vụ nghiệp vụ thay vì đưa vào quy trình đa tác tử sinh học liệu.

Dịch vụ slide/giáo án là lớp mặt tiền cho cả hai tác vụ sinh slide và giáo án. Dịch vụ này truy xuất dữ liệu từ lớp tri thức, tạo đầu vào cho bộ điều phối nội dung, quản lý bước duyệt dàn ý có con người tham gia, và lưu thông tin tóm tắt để có thể tiếp tục quy trình ở lượt tương tác sau.

Các bộ xử lý giải thích, hội thoại tự do và xử lý dự phòng đảm nhiệm các nhánh hội thoại hẹp hơn. Với câu hỏi cần tri thức SGK, bộ định tuyến gọi RAG trước khi đưa ngữ cảnh vào bộ xử lý; với hội thoại tự do, hệ thống có thể bỏ qua RAG để giảm độ trễ.

0.3.4 Thiết kế Quy trình Đa tác tử cho Slide và Giáo án

Hai chức năng sinh slide và sinh giáo án có cùng bản chất nghiệp vụ: cần lấy nội dung SGK liên quan, lập trình tự sự phạm, viết nội dung chi tiết, gợi ý media, sinh hoạt động đánh giá nhúng, hợp nhất kết quả trung gian và kiểm tra chất lượng. Vì vậy hệ thống dùng chung một bộ điều phối nội dung thay vì duy trì hai bộ điều phối riêng. Khác biệt giữa hai tác vụ được biểu diễn bằng loại học liệu cần sinh: slide hoặc giáo án.



Hình 0.5: Pipeline đa tác tử nội bộ cho sinh slide và giáo án

Giao tiếp giữa bộ điều phối và các agent chuyên trách sử dụng hợp đồng A2A-lite nội bộ. Mỗi nhiệm vụ được mô tả bằng bên gửi, bên nhận, loại nhiệm vụ, mục tiêu, dữ liệu vào, ràng buộc và kết quả kỳ vọng. Agent trả về trạng thái xử lý, kết quả trung gian, mức tin cậy, cảnh báo, danh sách công cụ đã dùng, độ trễ và lỗi nếu có. Các kết quả này được lưu trong trạng thái của quy trình qua ba nhóm dữ liệu: nhiệm vụ đã giao, kết quả agent và danh mục kết quả trung gian.


Agent lập kế hoạch sự phạm tạo dàn ý và trình tự học tập. Agent viết nội dung tạo nội dung chi tiết cho từng slide hoặc từng mục trong giáo án dựa trên dàn ý và ngữ cảnh nguồn. Agent gợi ý media hiện đề xuất thông tin hình ảnh và tài nguyên; tìm kiếm ảnh và kiểm tra URL qua công cụ ngoài được xem là điểm mở rộng, chưa mô tả như năng lực production hoàn chỉnh. Agent đánh giá nhúng chỉ sinh câu hỏi hoặc hoạt động đánh giá trong slide/giáo án, không thay thế dịch vụ quiz độc lập. Agent hậu kiểm chất lượng kiểm tra độ đúng sự kiện, độ bao phủ, tính sự phạm và

định dạng sau khi hợp nhất.

Thành phần hợp nhất kết quả không được xem là agent. Đây là service/tool xác định, có nhiệm vụ hợp nhất dàn ý, nội dung, media và phần đánh giá thành danh sách slide/section cuối cùng. Việc tách bước hợp nhất khỏi agent giúp hệ thống tránh gán tính tự trị cho một bước không cần suy luận LLM.

0.3.5 Thiết kế Lớp Tri thức (Knowledge Layer)

Lớp Tri thức cung cấp giao diện truy xuất chính cho các thành phần nghiệp vụ. Bên trong, bộ truy xuất thích nghi sử dụng bộ phân loại truy vấn dựa trên heuristic, không gọi LLM, để chọn chiến lược truy xuất phù hợp với loại câu hỏi và phạm vi lớp/bộ sách/chủ đề.



Hình 0.6: Cấu trúc xử lý và truy xuất thông tin của Knowledge Layer

STANDARD phục vụ các truy vấn cụ thể bằng Hybrid Search: Custom BM25 và semantic search được hợp nhất qua RRF, sau đó đi qua Cross-Encoder Reranker để lấy nhóm khối dữ liệu liên quan nhất. **BROAD** dùng tra cứu thông tin mô tả trên các khối mục tiêu, phù hợp với truy vấn tổng quan. **CURRICULUM** trả danh sách

bài/chủ đề đã khử trùng lặp, không cần tìm kiếm vector. **HIERARCHICAL** trước tiên tìm các khối cha ở cấp cao, sau đó tìm tiếp các khối con trong cùng bài/chủ đề.

Nếu **BROAD** hoặc **HIERARCHICAL** không tìm đủ ngữ cảnh, hệ thống có thể chuyển sang **STANDARD** để bảo vệ độ phủ. Sau truy xuất, bộ kết hợp ngữ cảnh định dạng thông tin theo loại tác vụ: các tác vụ hỏi đáp hoặc quiz ưu tiên thứ tự điểm liên quan, còn slide và giáo án nhóm ngữ cảnh theo chủ đề/bài học để giữ mạch sự phạm.


Kiến trúc MCP trong project hiện ở dạng lớp công cụ chạy trong tiến trình, gồm thành phần quản lý client, server và danh mục công cụ. Các công cụ chính phục vụ truy xuất tri thức và định dạng nội dung. Chức năng tìm kiếm web được xem là điểm mở rộng cho media/resource search, không phải kết quả thực nghiệm chính trong chương này.

0.3.6 Thiết kế Lớp Sinh phản hồi và Hậu kiểm (Generation & Validation)

Tầng sinh và hậu kiểm hiện không còn là một bộ kiểm tra chung cho mọi nhánh. Hệ thống tách rõ hai đường kiểm soát chất lượng: quiz độc lập và quy trình sinh slide/giáo án.

Ở nhánh quiz độc lập, yêu cầu của người dùng thường tạo ra một đối tượng có vòng đời tương tác dài. Câu hỏi sau khi sinh không chỉ được trả về ngay, mà còn được lưu để phục vụ chấm điểm, giải thích đáp án, ôn câu sai và thống kê tiến độ. Vì vậy nhánh này cần kiểm soát chặt chất lượng từng câu hỏi trước khi ghi vào trạng thái phiên.

Ở nhánh slide và giáo án, đầu ra là một sản phẩm tổng hợp gồm nhiều phần nội dung. Các agent chuyên trách tạo từng nhóm nội dung riêng, sau đó bước hợp nhất ghép kết quả theo một quy tắc xác định trước khi chuyển sang hậu kiểm. Agent hậu kiểm chất lượng không thay thế các agent sinh nội dung, mà chỉ đánh giá kết quả đã hợp nhất để quyết định chấp nhận, yêu cầu sửa lại hoặc chặn đầu ra lỗi nghiêm trọng.




Hình 0.7: Hai đường sinh và hậu kiểm chất lượng trong hệ thống

Với **quiz độc lập**, dịch vụ quiz lấy ngữ cảnh từ RAG, gọi bộ sinh tương ứng với loại câu hỏi, chạy hậu kiểm chất lượng, có thể yêu cầu sửa một lần, sau đó kiểm tra câu hỏi theo tiêu chí và nguồn tham chiếu. Chỉ những câu hỏi được phê duyệt mới được lưu vào trạng thái lượt làm quiz. Các bước chấm điểm, ôn câu sai và thống kê tiếp tục đọc từ trạng thái quiz này.

Với **slide và giáo án**, dịch vụ slide gọi bộ điều phối nội dung. Sau khi các agent chuyên trách trả kết quả, bước hợp nhất ghép các phần thành đầu ra cuối. Agent hậu kiểm đánh giá độ đúng sự kiện, độ bao phủ, tính sư phạm và định dạng. Nếu kết quả chưa đạt, bộ điều phối có thể định tuyến lại agent chịu trách nhiệm để sửa; nếu lỗi nghiêm trọng, đầu ra bị chặn thay vì trả về người dùng.

0.3.7 Thiết kế Trả phản hồi, Lưu phiên và Ghi vết

Chặng cuối của quy trình chịu trách nhiệm trả kết quả theo luồng, ghi vết thực thi và lưu trạng thái phiên. Thiết kế này giúp người dùng nhận phản hồi sớm trong khi hệ thống vẫn giữ được lịch sử đủ để tiếp tục các tác vụ tương tác như chấm bài, ôn câu sai hoặc tiếp tục quy trình sinh slide/giáo án.



Hình 0.8: Khối phản hồi, ghi trace và lưu trạng thái phiên

Bộ nhớ phiên lưu dữ liệu cục bộ dưới dạng JSON, cho phép hệ thống khôi phục lịch sử hội thoại, trạng thái quiz và trạng thái slide giữa các lượt tương tác. Thành phần ghi vết lưu lại đường đi của yêu cầu, bao gồm các bước thực thi phục vụ gỡ lỗi. Riêng với quy trình slide/giáo án, khi bộ điều phối nội dung dừng ở bước duyệt dàn ý, dịch vụ slide lưu thông tin tiếp tục gồm mã luồng, cấu hình luồng, cờ tạm dừng và loại học liệu để nối lại đúng quy trình sau khi người dùng gửi phản hồi.

0.4 Đánh giá hiệu năng và Kết quả thực nghiệm

0.4.1 Phương pháp đánh giá

Hệ thống sử dụng phương pháp đánh giá định lượng dành riêng cho hệ thống Retrieval-Augmented Generation (RAG) thông qua Ragas framework. Tập dữ liệu kiểm thử gồm 246 mẫu câu hỏi và đáp án tham chiếu được trích xuất từ dữ liệu giáo khoa, tập trung vào nhiều cấp độ hành vi nhận thức từ nhận biết, thông hiểu đến vận dụng.

Quá trình đánh giá được thực hiện trên 4 độ đo cốt lõi của Ragas:

Faithfulness (Độ trung thực): Đo lường mức độ câu trả lời của mô hình bám sát vào ngữ cảnh mà hệ thống truy xuất được. Mức điểm cao chứng tỏ mô hình không bịa đặt thông tin ngoài nguồn.

Answer Relevancy (Độ phù hợp): Đánh giá xem câu trả lời có giải quyết trực tiếp truy vấn ban đầu của người dùng hay không, tránh trả lời lan man hoặc sai trọng tâm.

Context Precision (Độ chính xác ngữ cảnh): Đánh giá khả năng xếp hạng của cụm truy xuất. Điểm số cao đồng nghĩa với việc các tài liệu liên quan nhất được xếp ở các thứ hạng đầu.

Context Recall (Độ bao phủ ngữ cảnh): Đo lường khả năng hệ thống tìm ra đầy đủ các thông tin cần thiết từ cơ sở tri thức so với đáp án tham chiếu.

0.4.2 Kết quả thực nghiệm phân hệ RAG

Sau quá trình chạy tự động 246 mẫu thử trên quy trình RAG của hệ thống, kết quả điểm số đánh giá trung bình trên các độ đo như sau:

Chỉ số đánh giá (Metric)	Điểm số trung bình (Mean)
Faithfulness (Độ trung thực)	0.9757
Answer Relevancy (Độ thiết thực của câu trả lời)	0.8571
Context Precision (Độ chính xác của ngữ cảnh)	0.8555
Context Recall (Độ bao phủ của ngữ cảnh)	0.9593

Bảng 1: Kết quả đánh giá hệ thống theo framework Ragas

Phân tích kết quả: Faithfulness đạt 0.9757 và Context Recall đạt 0.9593. Kết quả này cho thấy chiến lược Hierarchical RAG kết hợp với chunking theo phân cấp SGK đã giúp hệ thống truy xuất được phần lớn các đơn vị kiến thức cần thiết, đồng

thời hạn chế hiện tượng sinh thông tin ngoài ngữ cảnh.

Context Precision (0.8555) và **Answer Relevancy (0.8571)** ổn định quanh mức 85%. Kết quả này phản ánh hiệu quả của việc kết hợp BM25, semantic search, RRF và Cross-Encoder Reranker trong việc đưa các khối dữ liệu liên quan lên nhóm đầu. Khi ngữ cảnh đầu vào có độ liên quan cao hơn, lời nhắc sinh câu trả lời có cơ sở tốt hơn để bám sát trọng tâm câu hỏi.

Các tầng chất lượng trong hệ thống đóng vai trò hậu kiểm theo từng loại tác vụ. Các thành phần này không thay thế RAG, mà bổ sung thêm lớp kiểm soát để giảm rủi ro trả về nội dung sai, thiếu căn cứ hoặc không đúng định dạng.

0.4.3 Đánh giá độ trễ hệ thống (Latency)

Bên cạnh chất lượng phản hồi, hệ thống còn được đo đạc về mặt thời gian thực thi nhằm đánh giá trải nghiệm người dùng thực tế. Các chỉ số thời gian được ghi nhận cho mỗi truy vấn đầy đủ như sau:

Thành phần thực thi	Thời gian trung bình (Giây)
Khối truy xuất (Retriever & Reranker)	4.579
Khối sinh câu trả lời (LLM Generator)	1.979
Tổng thời gian xử lý	6.558

Bảng 2: Thống kê thời gian trễ của các khối kiến trúc trong hệ thống

Tổng thời gian cho một vòng xử lý RAG đầy đủ đạt trung bình xấp xỉ 6.5 giây. Trọng số thời gian chủ yếu nằm ở khâu truy xuất và reranking do hệ thống phải thực hiện Hybrid Search, hợp nhất kết quả và tái xếp hạng bằng Cross-Encoder. Tuy nhiên, cơ chế streaming ở tầng phản hồi giúp người dùng nhận kết quả theo từng phần thay vì phải chờ toàn bộ nội dung hoàn tất mới hiển thị.

Chương này đã trình bày hiện trạng triển khai của hệ thống trợ lý giáo dục theo vòng đời xử lý một yêu cầu. Kiến trúc hiện tại sử dụng trạng thái yêu cầu trung tâm, bộ điều phối mỏng, bộ định tuyến thực thi và các dịch vụ nghiệp vụ để xử lý từng nhóm tác vụ. Quy trình sinh slide và giáo án được tách thành một nhánh đa tác tử riêng, trong khi quiz độc lập tiếp tục được quản lý bởi dịch vụ quiz để bảo toàn các chức năng chấm điểm, ôn tập và thống kê.

Các kết quả thực nghiệm cho thấy quy trình RAG đạt điểm cao ở hai khía cạnh trung thực và bao phủ ngữ cảnh. Điều này phù hợp với mục tiêu của đề án là xây dựng một hệ thống sinh phản hồi có căn cứ từ SGK thay vì chỉ dựa vào tri thức nội tại của mô hình ngôn ngữ lớn. Những kết quả và giới hạn triển khai được trình bày

trong chương này là cơ sở để Chương 5 phân tích sâu hơn các giải pháp và đóng góp kỹ thuật của đề án.