

ĐẠI HỌC BÁCH KHOA HÀ NỘI

# ĐỒ ÁN TỐT NGHIỆP

Ứng dụng Mô hình ngôn ngữ lớn và Tác tử AI trong  
xây dựng hệ thống hỗ trợ học tập

NGUYỄN KHẮC ĐIỆP  
diep.nk225806@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin Việt-Nhật

**Giảng viên hướng dẫn:** TS. Ngô Văn Linh

**Ngành:** Công nghệ thông tin

**Trường:** Công nghệ thông tin và Truyền thông

**HÀ NỘI, 06/2026**

ĐẠI HỌC BÁCH KHOA HÀ NỘI

# ĐỒ ÁN TỐT NGHIỆP

Ứng dụng Mô hình ngôn ngữ lớn và Tác tử AI trong  
xây dựng hệ thống hỗ trợ học tập

NGUYỄN KHẮC ĐIỆP

diep.nk225806@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin Việt-Nhật

**Giảng viên hướng dẫn:** TS. Ngô Văn Linh \_\_\_\_\_

Chữ kí GVHD

**Khoa:** Công nghệ thông tin Việt-Nhật

**Trường:** Công nghệ Thông tin và Truyền thông

**HÀ NỘI, 06/2022**

# LỜI CẢM ƠN

Để hoàn thành đồ án này, em xin gửi lời cảm ơn chân thành đến quý thầy cô đã tận tâm hướng dẫn và trang bị kiến thức chuyên môn quý báu. Con xin cảm ơn gia đình vì luôn là chỗ dựa tinh thần vô giá. Cảm ơn những người bạn đồng hành và đặc biệt là người yêu đã luôn thấu hiểu, san sẻ áp lực và động viên em trong suốt thời gian qua. Và cuối cùng, tôi muốn gửi lời cảm ơn đến chính bản thân mình vì đã không bỏ cuộc, luôn chăm chỉ, kiên định và quyết tâm nỗ lực vượt qua mọi thử thách để hoàn thiện công việc với kết quả tốt nhất. Sự đồng hành của tất cả mọi người là động lực to lớn giúp em đạt được cột mốc này. Xin trân trọng cảm ơn!

# TÓM TẮT NỘI DUNG ĐỒ ÁN

Trong bối cảnh chuyển đổi số giáo dục, học sinh và giáo viên Trung học Phổ thông (đặc biệt môn Tin học) đối mặt với nhiều thách thức. Học sinh cần môi trường học tương tác, còn giáo viên mất nhiều thời gian soạn giáo án, sinh bài tập và chấm điểm. Mặc dù các mô hình ngôn ngữ lớn (LLM) mang lại tiềm năng lớn, chúng vẫn gặp rào cản về việc sinh thông tin sai lệch (hallucination) và không bám sát chương trình chuẩn. Từ đó, bài toán đặt ra là xây dựng một trợ lý ảo giáo dục thông minh có khả năng xử lý tự động, chính xác các tác vụ dựa trên nguồn tri thức chuẩn mực.

Nghiên cứu ứng dụng kiến trúc tìm kiếm và sinh văn bản (RAG) kết hợp phương pháp điều phối đa tác nhân (Multi-Agent LLM). Cụ thể, cơ sở dữ liệu vector được xây dựng từ sách giáo khoa chuẩn. Quá trình truy xuất dữ liệu áp dụng tìm kiếm lai (từ khóa và ngữ nghĩa), tối ưu bằng thuật toán Reciprocal Rank Fusion và mạng Cross-Encoder để xếp hạng lại nhằm trích xuất chính xác ngữ cảnh. Đồng thời, hệ thống bóc tách, đánh giá và định tuyến đa ý định thông qua bộ điều khiển luồng trung tâm (Pipeline Controller). Các dịch vụ miền sau đó xử lý lệnh song song cho các tác vụ như hỏi đáp, sinh bài tập đa định dạng, chấm điểm tự luận theo tiêu chí và tạo cấu trúc bài giảng.

Thử nghiệm trên 246 mẫu kiểm thử bằng khung đo lường RAGAS cho kết quả rất khả quan. Hệ thống đạt tính trung thực (Faithfulness) 0.975 giúp khắc phục gần như hoàn toàn hiện tượng ảo giác, độ phủ ngữ cảnh (Context Recall) đạt 0.959 và mức độ liên quan (Answer Relevancy) đạt 0.857. Tốc độ phản hồi trung bình của toàn hệ thống duy trì ổn định ở mức 6,5 giây cho mỗi truy vấn phức tạp.

Nghiên cứu cung cấp một giải pháp công nghệ giáo dục (EdTech) hiệu quả, hỗ trợ tự động hóa một số quy trình dạy và học môn Tin học THPT. Đo thời, kết quả chứng minh sự thành công của kiến trúc lai RAG và Multi-Agent trong việc định hướng LLM, tạo nền tảng vững chắc để phát triển các hệ sinh thái học tập cá nhân hóa sâu rộng hơn.

Sinh viên thực hiện  
(Ký và ghi rõ họ tên)

# ABSTRACT

In the digital transformation of education, high school students and teachers face notable challenges in Computer Science. Students need interactive self-study environments, while teachers spend excessive time planning lessons, creating quizzes, and grading. Although Large Language Models (LLMs) offer high potential, they suffer critically from information hallucination and a lack of grounding to authorized curricula. Thus, this project proposes an automated, intelligent virtual educational assistant strictly bounded by standardized knowledge bases.

To resolve these challenges, the research introduces a system structured on a Retrieval-Augmented Generation (RAG) architecture orchestrated by a Multi-Agent LLM approach. A vector database was built indexing textbook content from grades 10 to 12. The retrieval pipeline employs a Hybrid Search strategy optimized by Reciprocal Rank Fusion and a Cross-Encoder model for precise Vietnamese document reranking. Driven by a Thin Pipeline Controller that supports dynamic multi-intent routing, domain services parallelly handle complex workflows. These include standard knowledge queries, context-aware quiz generation in varying formats, criteria-based semantic answer grading, and structured lesson plan generation.

Evaluated using the RAGAS framework across 246 comprehensive test instances, the system attained outstanding metrics. It recorded a Faithfulness score of 0.975 (virtually eliminating hallucinations), a Context Recall score of 0.959, and an Answer Relevancy score of 0.857. Furthermore, the framework demonstrated robust performance, achieving an average response latency of 6.5 seconds per multi-intent query.

Ultimately, this thesis presents a scalable EdTech solution that pragmatically automates pedagogical steps for High School Computer Science. It empirically affirms the capability of hybrid retrieval architectures coupled with multi-agent orchestration to mitigate language model hallucinations structurally. This establishes a firm foundation for deploying proactive, personalized learning ecosystems in Vietnam.

## Danh mục ký hiệu và chữ viết tắt

| Ký hiệu | Ý nghĩa tiếng Anh                 | Ý nghĩa tiếng Việt                 |
|---------|-----------------------------------|------------------------------------|
| AI      | Artificial Intelligence           | Trí tuệ nhân tạo                   |
| API     | Application Programming Interface | Giao diện lập trình ứng dụng       |
| BM25    | Best Matching 25                  | Thuật toán đối sánh tốt nhất 25    |
| BPE     | Byte-Pair Encoding                | Một thuật toán mã hóa từ vựng      |
| CD      |                                   | Cánh điều (Sách giáo khoa)         |
| CoT     | Chain-of-Thought                  | Chuỗi tư duy                       |
| HyDE    | Hypothetical Document Embeddings  | Biểu diễn tài liệu giả định        |
| IDF     | Inverse Document Frequency        | Tần suất nghịch đảo tài liệu       |
| JSON    | JavaScript Object Notation        | Định dạng dữ liệu văn bản          |
| KNTT    |                                   | Kết nối tri thức (Sách giáo khoa)  |
| LLM     | Large Language Model              | Mô hình ngôn ngữ lớn               |
| NLP     | Natural language processing       | Xử lý ngôn ngữ tự nhiên            |
| Q&A     | Question and Answer               | Câu hỏi và câu trả lời             |
| RAG     | Retrieval-Augmented Generation    | Tạo sinh tăng cường bằng truy xuất |
| RRF     | Reciprocal Rank Fusion            | Kết hợp thứ hạng nghịch đảo        |
| SGK     |                                   | Sách giáo khoa                     |
| TF      | Term Frequency                    | Tần suất xuất hiện của từ          |



## Danh mục thuật ngữ chuyên ngành

| Thuật ngữ             | Giải thích ý nghĩa                                                                                                                                                                  |
|-----------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Agent</b>          | <i>(Tác tử)</i> - Hệ thống tự trị có lỗi là trí tuệ nhân tạo, có khả năng diễn dịch yêu cầu, lập suy luận và sử dụng công cụ để thực thi hành động.                                 |
| <b>Chunk</b>          | <i>(Phân đoạn)</i> - Một đoạn văn bản có ý nghĩa hoàn chỉnh được cắt nhỏ từ tài liệu gốc, có kích thước vừa vặn với bộ nhớ của mô hình ngôn ngữ.                                    |
| <b>Chunking</b>       | <i>(Phân mảnh dữ liệu)</i> - Kỹ thuật chia nhỏ các tài liệu quy mô lớn thành các chunk nhằm thuận tiện cho việc lập chỉ mục và tìm kiếm thông tin.                                  |
| <b>Context Window</b> | <i>(Cửa sổ ngữ cảnh)</i> - Giới hạn tối đa số lượng từ (hoặc token) mà một LLM có thể tiếp nhận và ghi nhớ trong một phiên xử lý duy nhất.                                          |
| <b>Embedding</b>      | <i>(Biểu diễn Vector/Nhúng)</i> - Kỹ thuật mã hóa ngôn ngữ tự nhiên thành các vector số học có độ phân giải cao, giúp máy tính có thể tính toán đo lường mức độ tương đồng ý nghĩa. |
| <b>Hallucination</b>  | <i>(Hiện tượng Ảo giác)</i> - Trạng thái mà mô hình ngôn ngữ lớn đưa ra những câu trả lời có hệ thống về ngoài rất tự tin nhưng hoàn toàn sai sự thật hoặc thiếu căn cứ.            |
| <b>Metadata</b>       | <i>(Siêu dữ liệu)</i> - Các thẻ thông tin đi kèm (như Tên bài học, Chương, Chủ đề) nhằm bổ trợ và cung cấp căn cứ nguồn gốc cho các chunk dữ liệu.                                  |
| <b>Multi-Agent</b>    | <i>(Đa tác tử)</i> - Một hệ thống phức hợp nơi nhiều tác tử (agent) hoạt động song song hoặc phối hợp nhằm giải tỏa áp lực của một tác vụ quá lớn.                                  |
| <b>Prompt</b>         | <i>(Chỉ thị)</i> - Câu lệnh hoặc ngữ cảnh đầu vào hướng dẫn mô hình ngôn ngữ lớn thực hiện trả lời, thiết lập phong cách hay xuất ra bằng định dạng nhất định.                      |
| <b>Reranker</b>       | <i>(Bộ xếp hạng lại)</i> - Mô hình máy học nâng cao làm nhiệm vụ rà soát, tinh chỉnh thứ tự các kết quả tìm ráp ban đầu để đẩy văn bản có liên đới chặt chẽ nhất lên cực đỉnh.      |

|                          |                                                                                                                                                                                                              |
|--------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Retriever</b>         | <i>(Bộ truy xuất)</i> - Thành phần thuật toán thực hiện tìm kiếm, quét qua toàn bộ cơ sở dữ liệu Vector để lấy ra cụm tài liệu thô gần khớp với truy vấn người dùng.                                         |
| <b>Token</b>             | <i>(Đơn vị cơ sở)</i> - Thành phần nhỏ nhất của một đoạn văn bản (có thể là một từ, âm tiết, hoặc cụm ký tự) mà máy tính có thể tách ra để xử lý.                                                            |
| <b>Vector Database</b>   | <i>(Cơ sở dữ liệu Vector)</i> - Cơ sở dữ liệu chuyên dụng được thiết kế nhằm lưu giữ và truy vấn tốc độ cao đối với dữ liệu kiểu vector đa chiều.                                                            |
| <b>Underthesea</b>       | <i>(Thư viện NLP tiếng Việt)</i> - Một bộ công cụ mã nguồn mở phụ vụ mạnh mẽ cho nhiều bài toán xử lý ngôn ngữ tự nhiên tiếng Việt, nổi bật là tách từ (Word Segmentation).                                  |
| <b>Word Segmentation</b> | <i>(Tách từ)</i> - Kỹ thuật phân tách chuỗi văn bản thành hệ thống các từ vựng hợp cấu trúc, đặc biệt quan trọng với ngôn ngữ không có định danh ranh giới sẵn bằng khoảng trắng (ví dụ từ ghép tiếng Việt). |

---

## MỤC LỤC

|                                                                            |           |
|----------------------------------------------------------------------------|-----------|
| <b>Danh mục ký hiệu và chữ viết tắt.....</b>                               | <b>i</b>  |
| <b>Danh mục thuật ngữ chuyên ngành .....</b>                               | <b>ii</b> |
| <b>CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....</b>                                    | <b>1</b>  |
| 1.1 Đặt vấn đề.....                                                        | 1         |
| 1.2 Mục tiêu và phạm vi đề tài.....                                        | 2         |
| 1.3 Định hướng giải pháp.....                                              | 3         |
| 1.4 Bố cục đồ án .....                                                     | 4         |
| <b>CHƯƠNG 2. KHẢO SÁT VÀ PHÂN TÍCH YÊU CẦU.....</b>                        | <b>6</b>  |
| 2.1 Khảo sát hiện trạng .....                                              | 6         |
| 2.2 Tổng quan chức năng .....                                              | 7         |
| 2.2.1 Biểu đồ use case tổng quát .....                                     | 7         |
| 2.2.2 Biểu đồ use case phân rã.....                                        | 7         |
| 2.3 Đặc tả chức năng .....                                                 | 10        |
| 2.3.1 Đặc tả UC02 - Hỏi đáp kiến thức SGK.....                             | 10        |
| 2.3.2 Đặc tả UC03 - Khởi tạo bộ câu hỏi/bài tập .....                      | 11        |
| 2.3.3 Đặc tả UC05 - Sinh slide bài giảng .....                             | 12        |
| 2.3.4 Đặc tả UC06 - Sinh giáo án.....                                      | 13        |
| 2.3.5 Quy trình nghiệp vụ .....                                            | 13        |
| 2.4 Yêu cầu phi chức năng .....                                            | 15        |
| <b>CHƯƠNG 3. NỀN TẢNG LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG.....</b>              | <b>17</b> |
| 3.1 Kiến thức nền tảng về Trí tuệ Nhân tạo và Xử lý ngôn ngữ tự nhiên..... | 17        |
| 3.1.1 Tokenization .....                                                   | 17        |
| 3.1.2 Biểu diễn vector .....                                               | 17        |
| 3.1.3 Kiến trúc Transformer và cơ chế Attention .....                      | 18        |

|                                                       |    |
|-------------------------------------------------------|----|
| 3.2 Mô hình ngôn ngữ lớn.....                         | 18 |
| 3.2.1 Bản chất dự đoán token tiếp theo .....          | 18 |
| 3.2.2 Prompt và khả năng gọi công cụ .....            | 19 |
| 3.2.3 Hiện tượng hallucination.....                   | 19 |
| 3.3 Retrieval-Augmented Generation .....              | 19 |
| 3.3.1 Kiến trúc RAG cơ bản .....                      | 19 |
| 3.3.2 Phân mảnh dữ liệu.....                          | 20 |
| 3.3.3 Tìm kiếm vector.....                            | 20 |
| 3.4 Truy xuất thông tin nâng cao .....                | 20 |
| 3.4.1 Tìm kiếm từ khóa.....                           | 20 |
| 3.4.2 Tìm kiếm lai và hợp nhất xếp hạng .....         | 21 |
| 3.4.3 Xếp hạng lại .....                              | 21 |
| 3.4.4 Tối ưu hóa truy vấn .....                       | 22 |
| 3.5 Adaptive Retrieval .....                          | 22 |
| 3.6 Điều phối yêu cầu và quản lý ngữ cảnh .....       | 22 |
| 3.6.1 Phân tích ý định và lập kế hoạch hành động..... | 23 |
| 3.6.2 Quản lý session và state .....                  | 23 |
| 3.7 Hệ thống đa tác tử và LangGraph .....             | 23 |
| 3.7.1 Tác tử AI và mô hình supervisor .....           | 23 |
| 3.7.2 Phạm vi áp dụng trong hệ thống .....            | 24 |
| 3.7.3 A2A-lite và Human-in-the-loop.....              | 24 |
| 3.8 Tool layer và MCP-like protocol.....              | 25 |
| 3.9 Đánh giá chất lượng hệ thống RAG .....            | 25 |
| 3.9.1 LLM-as-a-Judge .....                            | 25 |
| 3.9.2 Các thước đo RAG .....                          | 25 |
| 3.10 Kết chương.....                                  | 26 |

|                                                                                |           |
|--------------------------------------------------------------------------------|-----------|
| <b>CHƯƠNG 4. PHÂN TÍCH THIẾT KẾ, TRIỂN KHAI VÀ ĐÁNH GIÁ<br/>HỆ THỐNG .....</b> | <b>28</b> |
| 4.1 Môi trường và dữ liệu thực nghiệm.....                                     | 28        |
| 4.1.1 Môi trường phát triển .....                                              | 28        |
| 4.1.2 Dữ liệu thực nghiệm.....                                                 | 28        |
| 4.2 Tổng quan kiến trúc toàn bộ hệ thống .....                                 | 29        |
| 4.3 Thiết kế chi tiết các thành phần hệ thống.....                             | 30        |
| 4.3.1 Thiết kế Lớp Ngữ cảnh và Ý định (Context & Intent Layer) .....           | 30        |
| 4.3.2 Thiết kế Lớp Lập kế hoạch (Planning Layer).....                          | 32        |
| 4.3.3 Thiết kế Lớp Thực thi (Execution Layer) .....                            | 32        |
| 4.3.4 Thiết kế Quy trình Đa tác tử cho Slide và Giáo án .....                  | 33        |
| 4.3.5 Thiết kế Lớp Tri thức (Knowledge Layer) .....                            | 35        |
| 4.3.6 Thiết kế Lớp Sinh phản hồi và Hậu kiểm (Generation & Validation).....    | 36        |
| 4.3.7 Thiết kế Trả phản hồi, Lưu phiên và Ghi vết .....                        | 37        |
| 4.4 Đánh giá hiệu năng và Kết quả thực nghiệm.....                             | 39        |
| 4.4.1 Phương pháp đánh giá .....                                               | 39        |
| 4.4.2 Kết quả thực nghiệm phân hệ RAG.....                                     | 39        |
| 4.4.3 Đánh giá độ trễ hệ thống (Latency).....                                  | 40        |
| <b>CHƯƠNG 5. CÁC GIẢI PHÁP VÀ ĐÓNG GÓP NỔI BẬT .....</b>                       | <b>42</b> |
| 5.1 Điều phối request bằng thin orchestrator .....                             | 42        |
| 5.1.1 Vấn đề cần giải quyết.....                                               | 42        |
| 5.1.2 Giải pháp .....                                                          | 42        |
| 5.1.3 Đóng góp đạt được .....                                                  | 43        |
| 5.2 Truy xuất lại và Adaptive RAG .....                                        | 43        |
| 5.2.1 Vấn đề cần giải quyết.....                                               | 43        |
| 5.2.2 Giải pháp .....                                                          | 43        |

|                                                        |    |
|--------------------------------------------------------|----|
| 5.2.3 Đóng góp đạt được .....                          | 44 |
| 5.3 Multi-intent routing và action planning .....      | 44 |
| 5.3.1 Vấn đề cần giải quyết.....                       | 44 |
| 5.3.2 Giải pháp .....                                  | 44 |
| 5.3.3 Đóng góp đạt được .....                          | 45 |
| 5.4 Tách quiz standalone khỏi content assessment ..... | 45 |
| 5.4.1 Vấn đề cần giải quyết.....                       | 45 |
| 5.4.2 Giải pháp .....                                  | 45 |
| 5.4.3 Đóng góp đạt được .....                          | 46 |
| 5.5 Content multi-agent cho slide và giáo án.....      | 46 |
| 5.5.1 Vấn đề cần giải quyết.....                       | 46 |
| 5.5.2 Giải pháp .....                                  | 46 |
| 5.5.3 Đóng góp đạt được .....                          | 46 |
| 5.6 Human-in-the-loop tại bước duyệt dàn ý .....       | 47 |
| 5.6.1 Vấn đề cần giải quyết.....                       | 47 |
| 5.6.2 Giải pháp .....                                  | 47 |
| 5.6.3 Đóng góp đạt được .....                          | 47 |
| 5.7 Quality path, session và trace .....               | 47 |
| 5.7.1 Vấn đề cần giải quyết.....                       | 47 |
| 5.7.2 Giải pháp .....                                  | 47 |
| 5.7.3 Đóng góp đạt được .....                          | 48 |
| 5.8 Tool layer như điểm mở rộng có kiểm soát .....     | 48 |
| 5.8.1 Vấn đề cần giải quyết.....                       | 48 |
| 5.8.2 Giải pháp .....                                  | 48 |
| 5.8.3 Đóng góp đạt được .....                          | 48 |
| 5.9 Kết chương.....                                    | 48 |

|                                                          |           |
|----------------------------------------------------------|-----------|
| <b>CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN .....</b>      | <b>50</b> |
| 6.1 Kết luận.....                                        | 50        |
| 6.2 Hướng phát triển.....                                | 50        |
| <b>TÀI LIỆU THAM KHẢO.....</b>                           | <b>53</b> |
| <b>PHỤ LỤC.....</b>                                      | <b>55</b> |
| <b>A. HƯỚNG DẪN VIẾT ĐỒ ÁN TỐT NGHIỆP .....</b>          | <b>55</b> |
| A.1 Ngành học.....                                       | 56        |
| A.2 Đánh dấu (bullet) và đánh số (numering) .....        | 56        |
| A.3 Cách thêm bảng .....                                 | 57        |
| A.4 Chèn hình ảnh .....                                  | 57        |
| A.5 Tài liệu tham khảo .....                             | 58        |
| A.6 Cách viết phương trình và công thức toán học.....    | 58        |
| A.7 Qui cách đóng quyển.....                             | 58        |
| <b>B. ĐẶC TẢ USE CASE.....</b>                           | <b>60</b> |
| B.1 Đặc tả use case “Thống kê tình hình mượn sách” ..... | 60        |
| B.2 Đặc tả use case “Đăng ký làm thẻ mượn” .....         | 60        |

## DANH MỤC HÌNH VẼ

|          |                                                                  |    |
|----------|------------------------------------------------------------------|----|
| Hình 2.1 | Biểu đồ use case tổng quát . . . . .                             | 7  |
| Hình 2.2 | Biểu đồ phân rã Use Case Hỏi đáp kiến thức SGK . . . . .         | 8  |
| Hình 2.3 | Biểu đồ phân rã Use Case Khởi tạo bộ câu hỏi/bài tập . . . . .   | 8  |
| Hình 2.4 | Biểu đồ phân rã Use Case UC04 . . . . .                          | 9  |
| Hình 2.5 | Biểu đồ phân rã Use Case Sinh slide bài giảng . . . . .          | 9  |
| Hình 2.6 | Biểu đồ phân rã Use Case Sinh giáo án . . . . .                  | 10 |
| Hình 3.1 | Tổng quan các mô hình tổ chức trong hệ thống đa tác tử . . . . . | 24 |
| Hình 4.1 | Sơ đồ tổng quan kiến trúc hệ thống theo vòng đời xử lý yêu cầu   | 30 |
| Hình 4.2 | Chi tiết cấu trúc và luồng xử lý tại Lớp Ngữ cảnh và Ý định . .  | 31 |
| Hình 4.3 | Chu trình lập kế hoạch hành động bằng rule-based logic . . .     | 32 |
| Hình 4.4 | Sơ đồ vòng lặp đa tác vụ và điều phối dịch vụ nghiệp vụ . . .    | 33 |
| Hình 4.5 | Pipeline đa tác tử nội bộ cho sinh slide và giáo án . . . . .    | 34 |
| Hình 4.6 | Cấu trúc xử lý và truy xuất thông tin của Knowledge Layer . .    | 35 |
| Hình 4.7 | Hai đường sinh và hậu kiểm chất lượng trong hệ thống . . . .     | 36 |
| Hình 4.8 | Khối phản hồi, ghi trace và lưu trạng thái phiên . . . . .       | 38 |
| Hình A.1 | Internet vạn vật . . . . .                                       | 57 |
| Hình A.2 | Quy cách đóng quyển đồ án . . . . .                              | 59 |
| Hình A.3 | Quy cách đóng quyển đồ án . . . . .                              | 59 |



## DANH MỤC BẢNG BIỂU

|          |                                                                |    |
|----------|----------------------------------------------------------------|----|
| Bảng 2.1 | Đặc tả UC02 - Hỏi đáp kiến thức SGK . . . . .                  | 10 |
| Bảng 2.2 | Đặc tả UC03 - Khởi tạo bộ câu hỏi/bài tập . . . . .            | 11 |
| Bảng 2.3 | Đặc tả UC05 - Sinh slide bài giảng . . . . .                   | 12 |
| Bảng 2.4 | Đặc tả UC06 - Sinh giáo án . . . . .                           | 13 |
| Bảng 4.1 | Kết quả đánh giá hệ thống theo framework Ragas . . . . .       | 39 |
| Bảng 4.2 | Thống kê thời gian trễ của các khối kiến trúc trong hệ thống . | 40 |
| Bảng A.1 | Table to test captions and labels. . . . .                     | 57 |

# CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

## 1.1 Đặt vấn đề

Trong bối cảnh cuộc cách mạng công nghiệp lần thứ tư đang diễn ra mạnh mẽ trên toàn cầu, chuyển đổi số đã trở thành một trong những ưu tiên hàng đầu của Việt Nam trong chiến lược phát triển quốc gia. Giáo dục được xác định là một trong những lĩnh vực trọng điểm trong quá trình chuyển đổi số, việc ứng dụng công nghệ thông tin và trí tuệ nhân tạo (AI) vào dạy và học không chỉ là xu hướng tất yếu mà còn là yêu cầu cấp thiết để nâng cao chất lượng giáo dục.

Môn Tin học tại trường trung học phổ thông (THPT) đóng vai trò đặc biệt quan trọng trong chương trình giáo dục Việt Nam. Với chương trình mới bao gồm hai bộ sách giáo khoa Cánh Diều và Kết Nối Tri Thức với Cuộc Sống cho các lớp 10, 11 và 12, nội dung bao phủ nhiều chủ đề chuyên môn từ khoa học máy tính, mạng máy tính đến an toàn thông tin. Tuy nhiên, việc giảng dạy và học tập môn học này vẫn đối mặt với nhiều thách thức đáng kể.

Về phía học sinh, các em thường thiếu một công cụ hỗ trợ tự học hiệu quả và bám sát nội dung sách giáo khoa. Các chatbot AI phổ quát hiện nay như ChatGPT, Claude hay Gemini tuy có khả năng trả lời câu hỏi nhưng không được tối ưu cho dữ liệu sách giáo khoa Việt Nam, dẫn đến tình trạng đưa ra thông tin không chính xác (hallucination). Điều này đặc biệt nguy hiểm trong bối cảnh giáo dục khi mà việc tiếp thu kiến thức sai lệch có thể ảnh hưởng nghiêm trọng đến quá trình học tập. Bên cạnh đó, học sinh cũng thiếu nguồn bài tập đa dạng và phản hồi tức thời được thiết kế chuyên biệt theo từng bài học.

Về phía giáo viên, việc biên soạn tài liệu giảng dạy như câu hỏi trắc nghiệm, bài tập hay cấu trúc slide bài giảng đòi hỏi rất nhiều thời gian và công sức. Trong khi đó, hầu hết các nền tảng e-learning hiện có tại Việt Nam chỉ đóng vai trò là kho lưu trữ và phân phối bài giảng số, chưa có khả năng tự động khởi tạo nội dung thông minh dựa trên yêu cầu của người dùng.

Từ những phân tích trên, nhu cầu xây dựng một hệ thống trợ lý ảo giáo dục ứng dụng công nghệ Tăng cường truy xuất dữ liệu (RAG) sử dụng dữ liệu nền tảng là sách giáo khoa trở nên cấp thiết. Hệ thống này cần đáp ứng đầy đủ các mục tiêu bao gồm tự động trả lời câu hỏi dựa trên nội dung SGK, sinh bài tập đa dạng định dạng, phát thảo cấu trúc slide bài giảng và hỗ trợ giáo viên trong công tác soạn giảng, qua đó tối ưu hóa công việc của cả người dạy lẫn người học.

## 1.2 Mục tiêu và phạm vi đề tài

Trong những năm gần đây, việc ứng dụng trí tuệ nhân tạo vào giáo dục đã thu hút sự quan tâm của nhiều nhà nghiên cứu và doanh nghiệp trên thế giới. Các mô hình ngôn ngữ lớn (LLM) như ChatGPT, Claude hay Gemini đã chứng minh khả năng ấn tượng trong việc tạo sinh văn bản và trả lời câu hỏi. Tuy nhiên, khi được sử dụng trong bối cảnh giáo dục cụ thể, các mô hình này bộc lộ những hạn chế đáng kể. Đầu tiên, chúng không được huấn luyện trên dữ liệu sách giáo khoa Việt Nam, dẫn đến thường xuyên đưa ra câu trả lời không chính xác hoặc không phù hợp với nội dung chương trình học. Thứ hai, hiện tượng hallucination - tức là sinh ra thông tin nhìn có vẻ đáng tin cậy nhưng hoàn toàn sai sự thật - là vấn đề nan giải mà các LLM hiện tại vẫn chưa thể khắc phục triệt để.

Đối với các nền tảng e-learning trong nước như VnEdu, HOC247, hay Moon, các hệ thống này chủ yếu cung cấp kho tài liệu số và video bài giảng được biên soạn sẵn. Một số nền tảng đã tích hợp tính năng quiz tự động nhưng chưa có khả năng sinh câu hỏi theo yêu cầu cụ thể của người dùng hoặc dựa trên nội dung bài học mới được cập nhật. Việc quản lý và cập nhật ngân hàng câu hỏi vẫn phải thực hiện thủ công, tốn kém nhiều thời gian và công sức.

Về mặt kỹ thuật, công nghệ Retrieval-Augmented Generation (RAG) đã được chứng minh hiệu quả trong việc cải thiện độ chính xác của LLM bằng cách kết hợp khả năng truy xuất tài liệu với khả năng sinh ngôn ngữ tự nhiên. Nhiều nghiên cứu đã áp dụng RAG vào các bài toán giáo dục và đạt được những kết quả khả quan. Tuy nhiên, phần lớn các ứng dụng này tập trung vào các ngữ cảnh sử dụng tiếng Anh và chưa có nhiều nghiên cứu cụ thể cho việc xây dựng hệ thống RAG dựa trên sách giáo khoa Việt Nam. Đặc biệt, việc kết hợp kiến trúc Multi-Agent với RAG để tạo ra hệ thống đa tác vụ (quiz + slide + scoring) vẫn còn là lĩnh vực tương đối mới và chưa được khai thác nhiều trong bối cảnh giáo dục Việt Nam.

So sánh giữa các giải pháp hiện có cho thấy rõ sự khác biệt về năng lực. Trong khi các chatbot AI phổ quát có khả năng đối thoại tự do nhưng không đảm bảo tính chính xác theo SGK, các nền tảng e-learning trong nước có nguồn dữ liệu chuẩn nhưng thiếu khả năng tự động sáng tạo nội dung. Đề tài này hướng tới việc kết hợp ưu điểm của cả hai hướng tiếp cận: đảm bảo tính bám sát sách giáo khoa đồng thời có khả năng sinh tự động các nội dung giáo dục đa dạng.

Dựa trên các phân tích và đánh giá ở trên, đề tài này xác định các hạn chế cần khắc phục bao gồm: thiếu công cụ AI tối ưu cho việc học Tin học THPT tại Việt Nam; chưa có giải pháp RAG nào tích hợp đầy đủ các tác vụ quiz, slide và scoring; và chưa có hệ thống nào kết hợp Multi-Agent với cơ chế Human-In-The-

Loop (HITL) để đảm bảo chất lượng đầu ra trong việc sinh slide bài giảng.

Mục tiêu tổng quát của đề tài là xây dựng hệ thống trợ lý ảo giáo dục hỗ trợ việc dạy và học môn Tin học tại trường trung học phổ thông, sử dụng nền tảng là sách giáo khoa Tin học lớp 10, 11 và 12 thuộc hai bộ sách Cánh Diều và Kết Nối Tri Thức.

Các mục tiêu cụ thể bao gồm: nghiên cứu và xây dựng hệ thống truy xuất kiến thức từ sách giáo khoa dựa trên kiến trúc RAG; thiết kế và phát triển module sinh câu hỏi và bài tập tự động với nhiều định dạng bao gồm trắc nghiệm, tự luận, điền khuyết và đúng/sai; xây dựng module sinh cấu trúc slide bài giảng với kiến trúc đa tác tử; phát triển module chấm điểm và phản hồi tự động dựa trên ngữ cảnh bài học; cuối cùng là đánh giá hiệu năng hệ thống thông qua các chỉ số đánh giá chuẩn.

### 1.3 Định hướng giải pháp

Để giải quyết các vấn đề đã xác định ở phần trên, đề tài này lựa chọn định hướng giải pháp dựa trên sự kết hợp giữa công nghệ Retrieval-Augmented Generation (RAG) và kiến trúc Multi-Agent. Đây là hai công nghệ tiên tiến trong lĩnh vực AI hiện nay, có khả năng bổ trợ lẫn nhau để tạo ra một hệ thống vừa đảm bảo tính chính xác vừa có khả năng xử lý đa tác vụ phức tạp.

Về nền tảng LLM, hệ thống sử dụng mô hình ngôn ngữ lớn của Google với ưu điểm là chi phí thấp, khả năng hỗ trợ tiếng Việt tốt và chế độ sinh output có cấu trúc ổn định. Mô hình này được đánh giá là phù hợp với mục tiêu của đề tài khi cần tối ưu hóa chi phí trong khi vẫn đảm bảo chất lượng đầu ra cần thiết.

Về thành phần truy xuất, thay vì phụ thuộc vào các thư viện đóng gói, đề tài tự xây dựng bộ máy truy xuất kết hợp giữa thuật toán BM25 và tìm kiếm ngữ nghĩa (Semantic Search). Hai luồng kết quả này được hợp nhất thông qua thuật toán Reciprocal Rank Fusion (RRF). Cách tiếp cận này mang lại sự chủ động trong việc tối ưu hóa thuật toán cho văn bản tiếng Việt và tránh phụ thuộc vào các thư viện có thể gây tốn kém tài nguyên không cần thiết.

Về kiến trúc điều phối, hệ thống thiết kế một Orchestrator tại lớp mức lệnh cơ sở thay vì sử dụng các framework có sẵn. Orchestrator này đóng vai trò là bộ xử lý mỏng, điều phối các thành phần xử lý bao gồm ContextAnalyzer, SessionManager, ActionPlanner và RAG Agent. Ưu điểm của cách thiết kế này là toàn bộ quy trình xử lý được tối ưu về tốc độ, đồng thời quá trình theo vết và debug trở nên dễ dàng hơn.

Về kiến trúc Multi-Agent, hệ thống áp dụng mô hình Supervisor với Supervisor Agent đóng vai trò điều phối, tiếp nhận yêu cầu và phân loại đến các sub-agents

chuyên biệt bao gồm: OutlineAgent cho việc tạo dàn ý bài giảng, ContentAgent cho việc sinh nội dung chi tiết, MediaAgent cho việc tìm kiếm hình ảnh minh họa, QuizAgent cho việc sinh câu hỏi luyện tập, và MergeAgent cho việc tổng hợp kết quả. Hệ thống còn tích hợp cơ chế Human-In-The-Loop (HITL) cho phép người dùng duyệt và chỉnh sửa outline trước khi tiến hành sinh nội dung chi tiết.

Về đóng góp chính, đề tài này tự xây dựng bộ máy truy xuất từ mức cơ sở, thiết kế kiến trúc Adaptive RAG với nhiều chiến lược truy xuất khác nhau, xây dựng hệ thống Multi-Agent cho sinh slide bài giảng với các sub-agents chuyên biệt, và tích hợp cơ chế HITL trong quy trình sinh slide.

## **1.4 Bố cục đồ án**

Phần còn lại của báo cáo đồ án tốt nghiệp này được tổ chức như sau.

Chương 2 trình bày về việc khảo sát thực trạng và phân tích yêu cầu của hệ thống trợ lý ảo giáo dục. Trong chương này, em giới thiệu các tác nhân tham gia vào hệ thống, các Use case tổng quan và Use case phân rã, đồng thời đặc tả chi tiết các luồng chức năng chính bao gồm Hỏi đáp kiến thức SGK, Sinh câu hỏi và bài tập, Chấm điểm và phản hồi, và Sinh slide bài giảng.

Chương 3 giới thiệu về các công nghệ và kiến thức nền tảng được áp dụng trong đồ án. Em trình bày các khái niệm về Trí tuệ nhân tạo (AI) và Mô hình ngôn ngữ lớn (LLM), thuật toán Tokenization và Embedding, kiến trúc Transformer và cơ chế Attention. Ngoài ra, chương này cũng phân tích chi tiết công nghệ RAG bao gồm các thuật toán truy xuất, tìm kiếm lai, cùng với kiến trúc Multi-Agent và các phương pháp đánh giá hệ thống.

Chương 4 trình bày về việc thiết kế và cài đặt hệ thống. Em mô tả kiến trúc tổng thể của hệ thống với nhiều lớp xử lý bao gồm Context & Intent Layer, Planning Layer, Execution Layer, Knowledge Layer, Generation Layer và Response & Memory. Chương này trình bày chi tiết từng thành phần từ ContextAnalyzer, QueryRewriter, IntentRouter, SessionManager, ActionPlanner, cho đến RAG Service với nhiều chiến lược truy xuất, Quiz Service và Slide Service với kiến trúc Multi-Agent Supervisor.

Chương 5 trình bày về các giải pháp kỹ thuật đóng góp chính của đồ án. Em giới thiệu chi tiết về việc tự xây dựng bộ máy truy xuất từ mức cơ sở, thiết kế kiến trúc Orchestrator code-level, mô hình Adaptive RAG Agent với suy luận Heuristics, 2-Level Intent Detection, chiến lược quản lý Memory State, và hệ thống Multi-Agent với Supervisor pattern cho sinh slide bài giảng.

Cuối cùng, phần Kết luận tổng kết các kết quả đạt được của đồ án, đánh giá các

chỉ số hiệu năng, đồng thời đề xuất các hạn chế và hướng phát triển trong tương lai.

## CHƯƠNG 2. KHẢO SÁT VÀ PHÂN TÍCH YÊU CẦU

Chương này sẽ trình bày các nội dung liên quan đến việc khảo sát, phân tích hiện trạng để từ đó làm rõ các yêu cầu bài toán đối với hệ thống giáo dục AI. Các phân tích được dựa trên bối cảnh thực tế trong giảng dạy và học tập môn Tin học, qua đó đề xuất các chức năng chính của ứng dụng và mô hình hóa chúng thông qua các biểu đồ Use Case nhằm đưa ra một cái nhìn tổng quan và hệ thống.

### 2.1 Khảo sát hiện trạng

Trong bối cảnh chuyển đổi số giáo dục, việc ứng dụng trí tuệ nhân tạo (AI) mang lại nhiều tiềm năng to lớn, nhưng quá trình dạy và học môn Tin học THPT (các lớp 10, 11, 12 theo chương trình bộ Kết nối tri thức và Cánh diều) vẫn gặp nhiều thách thức.

Về phía học sinh, các em vẫn thiếu một công cụ hỗ trợ tự học bám sát nội dung chương trình trên lớp. Các chatbot AI phổ quát hiện nay (như ChatGPT, Claude) thường cung cấp câu trả lời phân tán, đôi khi sử dụng kiến thức nằm ngoài phạm vi sách giáo khoa Việt Nam, gây khó khăn cho việc ôn tập chuẩn xác. Bên cạnh đó, học sinh cũng thiếu các nguồn bài tập trắc nghiệm đa dạng được thiết kế chuyên biệt và phản hồi tức thời cho từng bài giảng để củng cố kiến thức một cách nhanh chóng.

Về phía giáo viên, công tác chuẩn bị bài giảng (soạn giáo án, thiết kế slide) và biên soạn đề kiểm tra đang tiêu tốn rất nhiều thời gian, công sức. Các thao tác tìm kiếm, chất lọc tư liệu từ các nguồn rời rạc trên mạng hiện nay vẫn chủ yếu được thực hiện thủ công, lặp đi lặp lại do thiếu vắng các công cụ hỗ trợ tự động hóa chuyên biệt ở mức độ sâu.

Khảo sát các giải pháp e-learning hiện có, phần lớn hệ thống mới chỉ đóng vai trò là kho lưu trữ và phân phối bài giảng số chứ chưa thể chủ động khởi tạo nội dung thông minh. Việc dùng trực tiếp các mô hình ngôn ngữ lớn khổng lồ mà không qua tinh chỉnh lại không đảm bảo được tính chính xác theo khuôn khổ tài liệu chuyên biệt quy định. Vì vậy, nhu cầu cấp thiết hiện nay là xây dựng một hệ thống trợ lý ảo giáo dục ứng dụng công nghệ tăng cường truy xuất dữ liệu (RAG) sử dụng dữ liệu nền tảng là sách giáo khoa. Hệ thống này sẽ đáp ứng trọn vẹn mục tiêu tự động trả lời câu hỏi, sinh bài tập, phát thảo giáo án và cấu trúc slide bài giảng, qua đó tối ưu hóa công việc của cả người dạy lẫn người học.

## 2.2 Tổng quan chức năng

Dựa trên các phân tích và các kết quả thu được từ tiến trình khảo sát hiện trạng, phần này sẽ mô tả tổng hợp lại các chức năng chính của phần mềm tương ứng với các phân quyền truy cập của người dùng. Hệ thống được thiết kế xoay quanh việc phục vụ nhóm người dùng cốt lõi nhằm giải quyết ba vấn đề lớn đã được nêu rõ thông qua các chức năng liên quan đến mục hỏi đáp kiến thức bài học, sinh biểu mẫu câu hỏi bài tập, tạo khung giáo án giáo khoa và thiết kế bài giảng trình chiếu tự động. Các chức năng chi tiết này sẽ được thiết kế tập trung để quy trình hóa và thiết lập toàn bộ các kết nối một cách hiệu quả nhất có thể. Dưới đây là các biểu đồ thiết kế để diễn giải một cách chi tiết về chức năng cũng như quy trình.

### 2.2.1 Biểu đồ use case tổng quát

Biểu đồ use case tổng quát mô tả các tác nhân và các chức năng chính của hệ thống.




Hình 2.1: Biểu đồ use case tổng quát

### 2.2.2 Biểu đồ use case phân rã

Dưới đây là các biểu đồ phân rã cho các chức năng chi tiết trong hệ thống giáo dục AI.




**a, Phân rã UC02 - Hỏi đáp kiến thức SGK**




**Hình 2.2:** Biểu đồ phân rã Use Case Hỏi đáp kiến thức SGK

**b, Phân rã UC03 - Khởi tạo bộ câu hỏi/bài tập**




**Hình 2.3:** Biểu đồ phân rã Use Case Khởi tạo bộ câu hỏi/bài tập

### c, Phân rã UC04




Hình 2.4: Biểu đồ phân rã Use Case UC04

### d, Phân rã UC05 - Sinh slide bài giảng



Hình 2.5: Biểu đồ phân rã Use Case Sinh slide bài giảng

## e, Phân rã UC06 - Sinh giáo án



Hình 2.6: Biểu đồ phân rã Use Case Sinh giáo án

### 2.3 Đặc tả chức năng

Dưới đây là đặc tả chi tiết cho các use case quan trọng của hệ thống:

#### 2.3.1 Đặc tả UC02 - Hỏi đáp kiến thức SGK

Bảng 2.1: Đặc tả UC02 - Hỏi đáp kiến thức SGK

| Mục            | Đặc tả                                                                                               |
|----------------|------------------------------------------------------------------------------------------------------|
| Tên use case   | UC02 - Hỏi đáp kiến thức SGK                                                                         |
| Tác nhân       | User                                                                                                 |
| Tiền điều kiện | (1) Hệ thống hoạt động bình thường; (2) Kho tri thức SGK đã được nạp; (3) User đang ở giao diện chat |

| Mục                            | Đặc tả                                                                                                                                                                                                                                                                                                   |
|--------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Luồng sự kiện chính</b>     | 1) User nhập câu hỏi kiến thức.<br>2) Hệ thống phân tích ngữ cảnh hội thoại và nhận diện intent.<br>3) Hệ thống truy xuất tri thức (RAG) theo chủ đề/lớp/bộ sách.<br>4) Hệ thống sinh câu trả lời dựa trên ngữ cảnh truy xuất.<br>5) Hiển thị câu trả lời cho User.                                      |
| <b>Luồng sự kiện phát sinh</b> | <b>A1:</b> Câu hỏi mơ hồ/phụ thuộc ngữ cảnh → hệ thống sinh đa truy vấn để tăng chất lượng truy xuất.<br><b>A2:</b> User chưa chọn bộ sách → hệ thống yêu cầu bổ sung thông tin bộ sách trước khi trả lời.<br><b>A3:</b> Không tìm thấy ngữ cảnh phù hợp → hệ thống trả thông báo và gợi ý cách hỏi lại. |
| <b>Hậu điều kiện</b>           | (1) Câu trả lời được trả về cho User; (2) Lịch sử hội thoại được cập nhật vào session; (3) Thông tin debug/trace được lưu                                                                                                                                                                                |

### 2.3.2 Đặc tả UC03 - Khởi tạo bộ câu hỏi/bài tập

**Bảng 2.2:** Đặc tả UC03 - Khởi tạo bộ câu hỏi/bài tập

| Mục                        | Đặc tả                                                                                                                                                                                                                                                                 |
|----------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Tên use case</b>        | UC03 - Khởi tạo bộ câu hỏi/bài tập                                                                                                                                                                                                                                     |
| <b>Tác nhân</b>            | User                                                                                                                                                                                                                                                                   |
| <b>Tiền điều kiện</b>      | (1) Hệ thống sẵn sàng; (2) Kho SGK khả dụng; (3) User cung cấp yêu cầu sinh câu hỏi                                                                                                                                                                                    |
| <b>Luồng sự kiện chính</b> | 1) User nhập yêu cầu tạo câu hỏi (chủ đề, dạng câu hỏi, số lượng).<br>2) Hệ thống nhận diện intent sinh câu hỏi.<br>3) Hệ thống truy xuất tri thức liên quan từ SGK.<br>4) Hệ thống sinh bộ câu hỏi theo định dạng yêu cầu.<br>5) Hiển thị danh sách câu hỏi cho User. |

| Mục                            | Đặc tả                                                                                                                                                                                                                                                                                      |
|--------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Luồng sự kiện phát sinh</b> | <p><b>A1:</b> User không nêu rõ loại câu hỏi → hệ thống dùng mặc định (ví dụ MCQ).</p> <p><b>A2:</b> User yêu cầu mức độ khó (planned) → hệ thống điều chỉnh prompt sinh câu hỏi theo mức độ.</p> <p><b>A3:</b> User muốn chỉnh sửa/xuất file → hệ thống mở rộng thao tác sau khi sinh.</p> |
| <b>Hậu điều kiện</b>           | (1) Bộ câu hỏi được tạo thành công hoặc trả lỗi có hướng dẫn; (2) Trạng thái quiz được lưu vào session để phục vụ chấm điểm/ôn tập tiếp theo                                                                                                                                                |

### 2.3.3 Đặc tả UC05 - Sinh slide bài giảng

**Bảng 2.3:** Đặc tả UC05 - Sinh slide bài giảng

| Mục                            | Đặc tả                                                                                                                                                                                                                                                                                                                                                                                                   |
|--------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Tên use case</b>            | UC05 - Sinh slide bài giảng                                                                                                                                                                                                                                                                                                                                                                              |
| <b>Tác nhân</b>                | User                                                                                                                                                                                                                                                                                                                                                                                                     |
| <b>Tiền điều kiện</b>          | (1) Hệ thống AI và RAG hoạt động; (2) User cung cấp chủ đề bài giảng; (3) Có thông tin lớp/bộ sách (hoặc xác định được tự động)                                                                                                                                                                                                                                                                          |
| <b>Luồng sự kiện chính</b>     | <p>1) User nhập yêu cầu sinh slide.</p> <p>2) Hệ thống nhận diện intent tạo slide.</p> <p>3) Hệ thống truy xuất tri thức SGK liên quan.</p> <p>4) Supervisor gọi agent tạo outline.</p> <p>5) Hệ thống sinh nội dung chi tiết từng slide.</p> <p>6) (Tùy chọn) sinh media và câu hỏi luyện tập.</p> <p>7) Hệ thống merge kết quả và kiểm tra chất lượng.</p> <p>8) Trả bộ slide hoàn chỉnh cho User.</p> |
| <b>Luồng sự kiện phát sinh</b> | <p><b>A1:</b> User duyệt/chỉnh sửa outline (HITL) trước khi tiếp tục sinh nội dung.</p> <p><b>A2:</b> Một agent phụ (media/quiz) lỗi → hệ thống tiếp tục với output một phần (partial) nếu lỗi vẫn đạt.</p> <p><b>A3:</b> Chưa có bộ sách → hệ thống yêu cầu User bổ sung.</p>                                                                                                                           |

| Mục                  | Đặc tả                                                                                                                       |
|----------------------|------------------------------------------------------------------------------------------------------------------------------|
| <b>Hậu điều kiện</b> | (1) Slide được tạo và hiển thị; (2) Dữ liệu slide lưu vào session; (3) Có thể tiếp tục chỉnh sửa/resume trong phiên hiện tại |

#### 2.3.4 Đặc tả UC06 - Sinh giáo án

**Bảng 2.4:** Đặc tả UC06 - Sinh giáo án

| Mục                            | Đặc tả                                                                                                                                                                                                                                                                  |
|--------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Tên use case</b>            | UC06 - Sinh giáo án                                                                                                                                                                                                                                                     |
| <b>Tác nhân</b>                | User                                                                                                                                                                                                                                                                    |
| <b>Tiền điều kiện</b>          | (1) Hệ thống hoạt động ổn định; (2) User cung cấp yêu cầu giáo án (chủ đề/lớp/mục tiêu)                                                                                                                                                                                 |
| <b>Luồng sự kiện chính</b>     | 1) User nhập yêu cầu sinh giáo án.<br>2) Hệ thống nhận diện intent sinh giáo án.<br>3) Hệ thống truy xuất tri thức từ SGK.<br>4) Hệ thống tạo cấu trúc giáo án.<br>5) Hệ thống sinh nội dung chi tiết theo cấu trúc.<br>6) Trả giáo án cho User.                        |
| <b>Luồng sự kiện phát sinh</b> | <b>A1:</b> User yêu cầu tùy chỉnh độ dài/mức chi tiết → hệ thống tái sinh nội dung theo tham số mới.<br><b>A2:</b> User yêu cầu xuất định dạng Markdown/Text → hệ thống thực hiện xuất file.<br><b>A3:</b> Ngữ cảnh truy xuất chưa đủ → hệ thống yêu cầu làm rõ chủ đề. |
| <b>Hậu điều kiện</b>           | (1) Giáo án được sinh và trả về; (2) Nội dung được lưu vào session; (3) Sẵn sàng cho chỉnh sửa/xuất bản                                                                                                                                                                 |

#### 2.3.5 Quy trình nghiệp vụ

Phần này mô tả các luồng hoạt động (Activity) cốt lõi của hệ thống thông qua các bước tương tác giữa Người dùng (User), Hệ thống điều phối (System) và các Mô hình ngôn ngữ lớn (LLM). Các quy trình được thiết kế nhằm tối ưu hóa khả năng phản hồi tự nhiên của AI dựa trên kiến thức sách giáo khoa có sẵn.

### a, Quy trình Hỏi đáp kiến thức SGK

Quy trình này diễn tả cách hệ thống xử lý khi học sinh hoặc giáo viên đặt các câu hỏi truy vấn về kiến thức môn học. Đây là quy trình áp dụng trực tiếp kiến trúc RAG (Retrieval-Augmented Generation).

#### Diễn giải quy trình:

- **Bước 1 (Tiếp nhận):** Người dùng nhập truy vấn vào giao diện chat.
- **Bước 2 (Đánh giá ngữ cảnh):** Hệ thống lấy câu hỏi hiện tại tại kết hợp cùng lịch sử hội thoại gần nhất đưa vào module Router (LLM) để nhận diện ý định. Nếu ý định được xác định là hỏi đáp, luồng RAG sẽ được kích hoạt.
- **Bước 3 (Viết lại truy vấn):** LLM thực hiện thiết kế lại câu hỏi ban đầu (Query Rewriting) hoặc sinh đa truy vấn (Multi-Query) nhằm làm rõ ngữ nghĩa và loại bỏ sự mơ hồ.
- **Bước 4 (Truy xuất tri thức):** Các câu hỏi sau khi viết lại được chuyển thành các vector đặc trưng (Embedding) và đối chiếu với Vector Database. Hệ thống áp dụng Hybrid Search (Semantic + BM25) để lấy ra các đoạn tài liệu (chunks) SGK liên quan nhất.
- **Bước 5 (Tổng hợp và xếp hạng):** Tài liệu thô được đưa qua mô hình Reranker để đánh giá chéo độ tương đồng và chọn ra Top K đoạn văn bản chính xác nhất làm ngữ cảnh (Context).
- **Bước 6 (Sinh văn bản):** Hệ thống xây dựng một prompt chứa câu hỏi gốc và ngữ cảnh Top K, sau đó gửi cho LLM để tạo ra câu trả lời cuối cùng. Câu trả lời gửi về cho người dùng và vòng hội thoại mới bắt đầu.

### b, Quy trình Khởi tạo bộ câu hỏi/bài tập

Giáo viên hoặc học sinh có thể yêu cầu hệ thống tạo ra một bài kiểm tra hoặc danh sách câu hỏi ôn tập dựa trên một chủ đề cụ thể.

#### Diễn giải quy trình:

- **Bước 1 (Tiếp nhận yêu cầu):** Người dùng cung cấp tham số tạo bài tập (ví dụ: "Tạo 5 câu hỏi trắc nghiệm bài Mạng máy tính lớp 10").
- **Bước 2 (Trích xuất tri thức):** Tương tự quy trình Hỏi đáp, hệ thống dùng RAG để lấy chính xác phần nội dung lý thuyết liên quan đến bài "Mạng máy tính" từ SGK để làm cơ sở.
- **Bước 3 (Xây dựng Prompt sinh bài tập):** Hệ thống nạp nội dung tài liệu vào cấu trúc prompt đặc thù (nghiêm ngặt về định dạng trả về - Structured

Output), yêu cầu LLM đóng vai trò giáo viên để sinh câu hỏi theo độ khó (Bloom's Taxonomy).

- **Bước 4 (Sinh và kiểm chứng):** LLM sinh bộ câu hỏi định dạng JSON/Markdown. Hệ thống sẽ có bước kiểm tra tự động xem dữ liệu trả về có bị lỗi format hay không, nếu lỗi sẽ yêu cầu LLM tự sửa.
- **Bước 5 (Trình bày & Xuất file):** Hệ thống hiển thị danh sách câu hỏi ra giao diện. Người dùng có thể làm trực tiếp hoặc thao tác tải tệp tin về máy.

### c, Quy trình Sinh slide bài giảng và Giáo án (Kiến trúc Multi-Agent)

Đây là quy trình phức tạp nhất nhằm hỗ trợ giáo viên tự động hóa việc chuẩn bị tài liệu giảng dạy. Hệ thống sử dụng cơ chế chia để trị (Fan-out) với mô hình đa tác tử (Multi-Agent).

#### Diễn giải quy trình:

- **Bước 1 (Nhập chủ đề):** Giáo viên nhập tên bài học hoặc một chủ đề mong muốn để tạo slide/giáo án.
- **Bước 2 (Lập dàn ý - Outline Generation):** Hệ thống dùng RAG lấy mục lục và nội dung cốt lõi của bài học đó, LLM trung tâm (Supervisor) sẽ tiến hành tạo Dàn ý khái quát (Outline) cho giáo án.
- **Bước 3 (Thực thi song song - Fan-out):** Sơ đồ được chia thành 3 nhánh xử lý độc lập do 3 Sub-Agent đảm nhiệm:
  - *Agent 1 (Mục tiêu & Khởi động):* Sinh phần kiến thức trọng tâm, yêu cầu cần đạt.
  - *Agent 2 (Lý thuyết chính):* Chia nhỏ dàn ý thành các slide/tiểu mục lý thuyết chuyên sâu, có ví dụ minh họa từ SGK.
  - *Agent 3 (Luyện tập & Vận dụng):* Đảm nhận việc sinh bài tập trắc nghiệm, tình huống thảo luận cuối bài.
- **Bước 4 (Tổng hợp - Fan-in):** Ngay khi 3 Agent hoàn thành, module Supervisor sẽ gom tất cả kết quả lại thành một bản nháp hoàn chỉnh duy nhất.
- **Bước 5 (Trình bày & Chỉnh sửa):** Trả kết quả hiển thị cho giáo viên dưới dạng Markdown. Giáo viên có thể yêu cầu hiệu chỉnh độ dài hoặc bổ sung chi tiết trước khi xuất thành file hoàn chỉnh.

## 2.4 Yêu cầu phi chức năng

Hệ thống Trợ lý ảo Giáo dục cần tuân thủ các yêu cầu phi chức năng sau để đảm bảo chất lượng và trải nghiệm người dùng:



- **Hiệu năng (Performance):** Hệ thống phản hồi các truy vấn RAG của người dùng trong khoảng thời gian lý tưởng dưới 5 giây. Đối với các tác vụ phức tạp như sinh slide, thời gian chờ tối đa không vượt quá 30 giây.
- **Độ tin cậy (Reliability):** Các kiến thức và nội dung được tạo ra phải bám sát 100% nội dung sách giáo khoa (Grounded), giảm thiểu tối đa hiện tượng "ảo giác" (Hallucination) từ LLM.
- **Tính dễ dùng (Usability):** Giao diện người dùng (UI) cần hiển thị trực quan, thân thiện (dựa trên Gradio), giúp giáo viên và học sinh dễ dàng tương tác mà không cần qua đào tạo về công nghệ phức tạp.
- **Tính mở rộng và bảo trì (Scalability & Maintainability):** Hệ thống được thiết kế theo kiến trúc module rời rạc thuần mã nguồn (Code-level Orchestrator), cho phép dễ dàng tích hợp thêm các Agent mới hoặc nâng cấp thư viện mà không làm gián đoạn hệ thống hiện tại.

## CHƯƠNG 3. NỀN TẢNG LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG

Sau khi Chương 2 đã khảo sát nhu cầu và xác định các yêu cầu chính của hệ thống, chương này trình bày các nền tảng lý thuyết và công nghệ được sử dụng để xây dựng trợ lý ảo giáo dục. Trọng tâm của chương không phải là mô tả chi tiết mã nguồn, mà là làm rõ các khái niệm cần thiết để hiểu các quyết định thiết kế ở các chương sau. Nội dung được tổ chức từ nền tảng xử lý ngôn ngữ tự nhiên, mô hình ngôn ngữ lớn, truy xuất tăng cường sinh, đến các cơ chế điều phối, đa tác tử và đánh giá chất lượng hệ thống.

### 3.1 Kiến thức nền tảng về Trí tuệ Nhân tạo và Xử lý ngôn ngữ tự nhiên

Hệ thống trợ lý ảo giáo dục xử lý đầu vào chủ yếu ở dạng ngôn ngữ tự nhiên. Vì vậy, các thành phần như tách đơn vị văn bản, biểu diễn ngữ nghĩa và mô hình hóa quan hệ giữa các từ đóng vai trò nền tảng cho cả pha truy xuất tri thức và pha sinh câu trả lời.

#### 3.1.1 Tokenization

Tokenization là quá trình chuyển văn bản thô thành các đơn vị nhỏ hơn gọi là token. Token có thể là ký tự, âm tiết, từ hoặc một phần của từ tùy theo bộ mã hóa được sử dụng. Với các mô hình ngôn ngữ hiện đại, tokenization thường không chỉ dựa trên khoảng trắng, vì cách làm này khó xử lý từ mới, tên riêng hoặc các biến thể chính tả. Một kỹ thuật phổ biến là Byte-Pair Encoding (BPE), trong đó hệ thống bắt đầu từ các đơn vị ký tự rồi lặp lại quá trình ghép các cặp xuất hiện thường xuyên để tạo token mới.

Đối với tiếng Việt, tokenization cần được xem xét cẩn thận vì một từ có thể gồm nhiều âm tiết tách nhau bằng khoảng trắng. Ví dụ, cụm “học sinh” và “sinh học” đều gồm hai âm tiết nhưng mang nghĩa khác nhau. Nếu chỉ tách theo khoảng trắng, hệ thống có thể làm mất ranh giới từ ghép và ảnh hưởng đến biểu diễn ngữ nghĩa, đặc biệt khi xây dựng kho tri thức hoặc tối ưu truy xuất.

#### 3.1.2 Biểu diễn vector

Mô hình máy học không xử lý trực tiếp văn bản như con người đọc câu chữ, mà cần biểu diễn văn bản thành vector số. Embedding là kỹ thuật ánh xạ token, câu hoặc đoạn văn thành vector dày đặc trong không gian nhiều chiều. Hai đoạn văn có ý nghĩa gần nhau thường có vector nằm gần nhau hơn so với các đoạn văn không liên quan.

Độ tương đồng giữa hai vector thường được tính bằng Cosine Similarity:

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}} \quad (3.1)$$

Trong đó,  $\mathbf{A}$  và  $\mathbf{B}$  là hai vector biểu diễn văn bản. Giá trị cosine càng gần 1 thì hai vector càng cùng hướng, tức hai văn bản càng gần nhau về mặt ngữ nghĩa. Đây là cơ sở cho tìm kiếm ngữ nghĩa trong hệ thống RAG.

### 3.1.3 Kiến trúc Transformer và cơ chế Attention

Transformer là kiến trúc nền tảng của nhiều mô hình ngôn ngữ hiện đại. Điểm khác biệt chính của Transformer so với các mô hình tuần tự trước đây là cơ chế tự chú ý, cho phép mô hình đánh giá mức độ liên quan giữa các token trong cùng một ngữ cảnh.

Cơ chế Scaled Dot-Product Attention được mô tả bởi công thức:

$$\text{Attention}(Q, K, V) = \text{softmax} \left( \frac{QK^T}{\sqrt{d_k}} \right) V \quad (3.2)$$

Trong đó,  $Q$  là truy vấn,  $K$  là khóa,  $V$  là giá trị, và  $d_k$  là số chiều của vector khóa. Thành phần  $\frac{QK^T}{\sqrt{d_k}}$  tính mức độ tương hợp giữa truy vấn và khóa, sau đó hàm softmax chuyển kết quả thành trọng số chú ý. Nhờ vậy, mô hình có thể ưu tiên các phần thông tin quan trọng trong câu hoặc đoạn văn.

## 3.2 Mô hình ngôn ngữ lớn

Mô hình ngôn ngữ lớn là thành phần sinh và suy luận ngôn ngữ trong hệ thống. Tuy nhiên, trong một trợ lý giáo dục, mô hình ngôn ngữ không nên được sử dụng như nguồn tri thức duy nhất. Các câu trả lời cần được neo vào dữ liệu sách giáo khoa và được kiểm soát bởi các lớp truy xuất, điều phối và đánh giá chất lượng.

### 3.2.1 Bản chất dự đoán token tiếp theo

LLM được huấn luyện để dự đoán token tiếp theo dựa trên chuỗi token đã có. Với một chuỗi có độ dài  $T$ , xác suất sinh chuỗi có thể được biểu diễn như sau:

$$P(w_1, w_2, \dots, w_T) = \prod_{t=1}^T P(w_t \mid w_1, \dots, w_{t-1}) \quad (3.3)$$

Trong đó,  $w_t$  là token tại vị trí  $t$ , còn  $w_1, \dots, w_{t-1}$  là ngữ cảnh trước đó. Khi sinh văn bản, mô hình chọn token tiếp theo dựa trên phân phối xác suất này. Cơ chế đó giúp LLM tạo được câu trả lời tự nhiên, nhưng cũng khiến mô hình có thể sinh

thông tin hợp lý về mặt ngôn ngữ mà không đúng với tài liệu nguồn.

### **3.2.2 Prompt và khả năng gọi công cụ**

Prompt là chỉ thị đầu vào dùng để định hướng hành vi của mô hình. Trong hệ thống trợ lý giáo dục, prompt không chỉ chứa câu hỏi của người dùng mà còn có thể chứa ngữ cảnh truy xuất từ sách giáo khoa, yêu cầu định dạng câu trả lời, hoặc ràng buộc về phạm vi lớp và bộ sách.

Khả năng gọi công cụ cho phép LLM không chỉ sinh văn bản tự do mà còn phát ra yêu cầu có cấu trúc để hệ thống thực hiện một thao tác cụ thể. Trong triển khai thực tế, việc gọi công cụ cần một lớp điều phối bên ngoài để kiểm soát quyền truy cập, kiểu dữ liệu vào ra và xử lý lỗi.

### **3.2.3 Hiện tượng hallucination**

Hallucination là hiện tượng mô hình sinh ra thông tin không có cơ sở trong dữ liệu nguồn hoặc trái với thực tế. Nguyên nhân đến từ bản chất dự đoán xác suất của LLM, giới hạn của dữ liệu huấn luyện và việc mô hình không tự kiểm chứng được tri thức tại thời điểm trả lời. Với bài toán giáo dục, hiện tượng này có rủi ro cao vì câu trả lời sai có thể ảnh hưởng trực tiếp đến quá trình học tập.

Vì vậy, hệ thống sử dụng kiến trúc RAG để truy xuất ngữ cảnh từ sách giáo khoa trước khi sinh câu trả lời. Cách tiếp cận này giúp câu trả lời có cơ sở dữ liệu rõ ràng hơn so với việc chỉ dựa vào tri thức tham số của mô hình ngôn ngữ lớn.

## **3.3 Retrieval-Augmented Generation**

Retrieval-Augmented Generation (RAG) là kiến trúc kết hợp truy xuất thông tin và sinh văn bản. Thay vì để LLM trả lời trực tiếp từ tri thức đã học, hệ thống trước hết tìm các đoạn tài liệu liên quan, sau đó đưa các đoạn này vào prompt để mô hình sinh câu trả lời dựa trên ngữ cảnh.

### **3.3.1 Kiến trúc RAG cơ bản**

Một hệ thống RAG thường gồm hai pha. Ở pha chuẩn bị dữ liệu, tài liệu được làm sạch, chia thành các đoạn nhỏ, chuyển thành embedding và lưu cùng metadata. Ở pha truy vấn, câu hỏi của người dùng được phân tích, chuyển thành vector hoặc từ khóa tìm kiếm, sau đó hệ thống lấy các đoạn tài liệu phù hợp nhất để đưa vào LLM.

Trong đề tài này, dữ liệu truy xuất chính là nội dung sách giáo khoa Tin học THPT thuộc các bộ sách được hỗ trợ. Do dữ liệu nguồn có cấu trúc theo lớp, bộ sách, chủ đề, bài học và mục nhỏ, metadata của từng đoạn văn có ý nghĩa quan trọng. Metadata giúp hệ thống giới hạn phạm vi truy xuất và tránh trộn lẫn nội dung giữa các lớp hoặc bộ sách khi người dùng đã nêu rõ yêu cầu.

### 3.3.2 Phân mảnh dữ liệu

Chunking là quá trình chia tài liệu dài thành các đoạn nhỏ hơn để phù hợp với giới hạn ngữ cảnh của mô hình và để tăng độ chính xác truy xuất. Nếu đoạn quá dài, kết quả truy xuất có thể chứa nhiều thông tin thừa; nếu đoạn quá ngắn, ngữ cảnh có thể bị đứt đoạn.

Các chiến lược chunking thường gặp gồm cắt theo kích thước cố định, cắt theo ranh giới đoạn hoặc câu, và cắt theo cấu trúc phân cấp của tài liệu. Với dữ liệu sách giáo khoa, hướng phân cấp có lợi thế vì giữ lại quan hệ giữa lớp, chương, bài và mục nội dung.

Trong phạm vi đồ án, mỗi bài học trong một cuốn sách được xem như một tài liệu nguồn tương đối độc lập. Vì vậy, việc chia nhỏ theo các heading trong bài học là lựa chọn phù hợp với bản chất dữ liệu. Cách chia này giúp mỗi chunk tương ứng với một đơn vị kiến thức có ranh giới sư phạm rõ ràng, chẳng hạn mục lý thuyết, ví dụ, hoạt động hoặc bài tập. Nếu chỉ chia theo độ dài cố định, hệ thống dễ cắt ngang một định nghĩa, một ví dụ hoặc một chuỗi hướng dẫn, làm giảm chất lượng ngữ cảnh khi truy xuất. Với dạng dữ liệu hiện có, chunking theo heading gần như là yêu cầu bắt buộc để hệ thống vừa truy xuất chính xác ở mức mục nhỏ, vừa mở rộng được phạm vi lên toàn bài khi cần sinh slide hoặc giáo án.

### 3.3.3 Tìm kiếm vector

Tìm kiếm vector sử dụng embedding để tìm các đoạn văn gần câu hỏi về mặt ngữ nghĩa. Cả câu hỏi và tài liệu đều được ánh xạ vào cùng một không gian vector. Sau đó, hệ thống dùng một độ đo tương đồng, chẳng hạn Cosine Similarity, để xếp hạng các đoạn tài liệu.

Cách tiếp cận này phù hợp với các câu hỏi diễn đạt khác với tài liệu gốc nhưng có cùng ý nghĩa. Tuy nhiên, tìm kiếm vector có thể kém hiệu quả với các từ khóa hiếm, tên lệnh, thuật ngữ kỹ thuật hoặc ký hiệu cụ thể. Vì vậy, hệ thống cần kết hợp thêm tìm kiếm từ khóa.

## 3.4 Truy xuất thông tin nâng cao

Trong một trợ lý giáo dục, chất lượng câu trả lời phụ thuộc mạnh vào chất lượng ngữ cảnh được truy xuất. Nếu hệ thống lấy sai hoặc thiếu tài liệu, LLM khó sinh câu trả lời đúng dù prompt được thiết kế tốt. Vì vậy, dự án sử dụng kết hợp tìm kiếm từ khóa, tìm kiếm ngữ nghĩa, hợp nhất xếp hạng và xếp hạng lại.

### 3.4.1 Tìm kiếm từ khóa

Tìm kiếm từ khóa dựa trên sự trùng khớp bề mặt giữa truy vấn và tài liệu. Một phương pháp nền tảng là TF-IDF, trong đó điểm của một từ tăng khi từ đó xuất

hiện nhiều trong tài liệu hiện tại và giảm khi từ đó xuất hiện quá phổ biến trong toàn bộ tập tài liệu:

$$TF\_IDF(t, d, D) = TF(t, d) \times IDF(t, D) \quad (3.4)$$

BM25 là một biến thể được sử dụng rộng rãi hơn trong truy xuất thông tin vì có cơ chế điều chỉnh ảnh hưởng của tần suất từ và độ dài tài liệu:

$$Score_{BM25}(Q, d) = \sum_{q_i \in Q} IDF(q_i) \cdot \frac{f(q_i, d) \cdot (k_1 + 1)}{f(q_i, d) + k_1 \cdot \left(1 - b + b \cdot \frac{|d|}{avgdl}\right)} \quad (3.5)$$

Trong đó,  $Q$  là truy vấn,  $f(q_i, d)$  là số lần từ khóa xuất hiện trong tài liệu  $d$ ,  $|d|$  là độ dài tài liệu và  $avgdl$  là độ dài trung bình của các tài liệu. Các tham số  $k_1$  và  $b$  điều chỉnh mức bão hòa tần suất và mức phạt theo độ dài tài liệu.

### 3.4.2 Tìm kiếm lai và hợp nhất xếp hạng

Tìm kiếm lai kết hợp ưu điểm của tìm kiếm từ khóa và tìm kiếm ngữ nghĩa. Tìm kiếm từ khóa phù hợp với thuật ngữ chính xác, còn tìm kiếm ngữ nghĩa phù hợp với cách diễn đạt linh hoạt. Khi hai cơ chế trả về hai danh sách kết quả khác nhau, hệ thống cần một phương pháp hợp nhất xếp hạng.

Reciprocal Rank Fusion (RRF) là một cách hợp nhất đơn giản và ổn định. Điểm RRF của một tài liệu  $d$  có thể được tính như sau:

$$Score_{RRF}(d) = \frac{1}{k + rank_{BM25}(d)} + \frac{1}{k + rank_{Vector}(d)} \quad (3.6)$$

Trong đó,  $rank_{BM25}(d)$  và  $rank_{Vector}(d)$  là vị trí của tài liệu trong từng danh sách kết quả, còn  $k$  là hằng số giảm ảnh hưởng của thứ hạng. RRF phù hợp khi kết hợp BM25 và tìm kiếm vector vì không yêu cầu hai loại điểm phải cùng thang đo.

### 3.4.3 Xếp hạng lại

Sau bước truy xuất ban đầu, hệ thống thường có một tập kết quả ứng viên. Reranking là bước đánh giá lại các ứng viên này với mô hình chính xác hơn. Trong khi bi-encoder mã hóa truy vấn và tài liệu riêng biệt để tìm kiếm nhanh, cross-encoder đưa cả cặp truy vấn và tài liệu vào cùng mô hình để đánh giá mức liên quan trực tiếp.

Cách làm này tốn chi phí tính toán hơn, nhưng chỉ áp dụng trên số lượng ứng viên nhỏ nên vẫn phù hợp trong pipeline RAG. Trong dự án, reranker được dùng để lọc nhiễu và chọn các đoạn ngữ cảnh cuối cùng trước khi đưa vào prompt.

### 3.4.4 Tối ưu hóa truy vấn

Truy vấn của người dùng thường ngắn, phụ thuộc ngữ cảnh hội thoại hoặc dùng cách diễn đạt khác với sách giáo khoa. Vì vậy, hệ thống có thể viết lại truy vấn hoặc sinh thêm truy vấn phụ để tăng độ phủ truy xuất. Query rewriting trong bối cảnh này không nhằm trả lời người dùng trực tiếp, mà nhằm tạo các biểu thức tìm kiếm rõ hơn cho RAG.

Khi câu hỏi phụ thuộc vào lịch sử hội thoại, hệ thống cần kết hợp chủ đề trước đó, lớp học hoặc bộ sách đã chọn vào truy vấn truy xuất. Điều này giúp các câu hỏi nối tiếp vẫn có đủ ngữ cảnh để tìm đúng tài liệu.

### 3.5 Adaptive Retrieval

Một chiến lược truy xuất cố định không phù hợp với mọi loại câu hỏi. Câu hỏi yêu cầu giải thích một khái niệm cụ thể cần các đoạn nội dung chi tiết, trong khi câu hỏi về chương trình học hoặc danh sách bài học lại cần tổng hợp metadata. Vì vậy, hệ thống sử dụng cơ chế adaptive retrieval để chọn cách truy xuất theo loại truy vấn.

Trong dự án, bộ phân loại truy vấn được cài đặt bằng luật heuristic. Thành phần này không dùng LLM, mà dựa trên tín hiệu từ câu hỏi, lớp, chủ đề, bộ sách và kết quả phân tích intent. Cách tiếp cận này giúp chiến lược truy xuất dễ kiểm soát.

Chiến lược STANDARD được dùng cho truy vấn cụ thể nhưng thiếu phạm vi lớp hoặc chủ đề rõ ràng. Chiến lược BROAD phù hợp với câu hỏi tổng quan, khi hệ thống cần lấy các đoạn đại diện cho nhiều bài học. Chiến lược CURRICULUM ưu tiên cấu trúc chương trình, danh sách bài hoặc chủ đề, nên sử dụng metadata nhiều hơn là tìm kiếm vector chi tiết. Chiến lược HIERARCHICAL được dùng khi truy vấn có đủ thông tin về lớp hoặc chủ đề; hệ thống trước hết chọn bài học liên quan, sau đó tìm các đoạn con chi tiết trong phạm vi đã chọn.

Cơ chế này giúp hệ thống cân bằng giữa độ chính xác và độ bao phủ của truy xuất. Với các tác vụ dài như tạo slide hoặc giáo án, hệ thống có thể lấy nhiều chunk hơn so với hỏi đáp thông thường.

### 3.6 Điều phối yêu cầu và quản lý ngữ cảnh

Một trợ lý giáo dục không chỉ thực hiện một thao tác hỏi đáp đơn lẻ. Người dùng có thể yêu cầu tạo câu hỏi, chấm đáp án, giải thích câu sai, tạo slide hoặc tiếp tục một nội dung đã trao đổi trước đó. Vì vậy, hệ thống cần một lớp điều phối để phân tích ý định, lập kế hoạch hành động và duy trì trạng thái.

### 3.6.1 Phân tích ý định và lập kế hoạch hành động

Intent detection là quá trình xác định mục đích của người dùng từ câu nhập tự nhiên. Với hệ thống này, một câu có thể chứa nhiều ý định. Ví dụ, người dùng có thể yêu cầu vừa tạo slide vừa thêm câu hỏi luyện tập. Khi đó, hệ thống cần phân tích thành nhiều intent và lập nhiều hành động tương ứng.

Sau khi phát hiện intent, action planning ánh xạ ý định sang thao tác cụ thể của hệ thống. Cách tách intent routing và action planning giúp phần suy luận ngôn ngữ được tách khỏi phần quyết định nghiệp vụ. LLM có thể hỗ trợ nhận diện ý định, nhưng việc chọn service xử lý cuối cùng cần được kiểm soát bằng logic rõ ràng để tránh gọi sai chức năng.

### 3.6.2 Quản lý session và state

Session memory lưu lịch sử hội thoại và trạng thái học tập của người dùng. Trạng thái này cần thiết cho các yêu cầu nối tiếp như chấm câu trả lời, ôn lại câu sai hoặc duyệt dàn ý slide.

Trong kiến trúc hiện tại, request được biểu diễn bằng một đối tượng ngữ cảnh đi qua các bước xử lý. Đối tượng này lưu câu hỏi gốc, truy vấn đã làm giàu, intent, action plan, phạm vi sách/lớp, thông tin session và các bước debug. Cách tổ chức này giúp tránh truyền nhiều biến rời rạc giữa các module và hỗ trợ trace khi cần kiểm tra hệ thống.


## 3.7 Hệ thống đa tác tử và LangGraph

Multi-agent system là cách tổ chức trong đó nhiều tác tử chuyên biệt cùng tham gia giải quyết một tác vụ phức tạp. Mỗi tác tử đảm nhận một vai trò hẹp hơn, chẳng hạn lập dàn ý, viết nội dung, gợi ý media, tạo đánh giá hoặc kiểm tra chất lượng. Cách chia này phù hợp với các tác vụ dài vì đầu ra trung gian có thể được kiểm soát và kết hợp lại.

### 3.7.1 Tác tử AI và mô hình supervisor

Một tác tử AI thường gồm mô hình ngôn ngữ, chỉ thị nhiệm vụ và khả năng gọi công cụ. Trong kiến trúc supervisor, một tác tử điều phối quyết định tác tử chuyên môn nào cần được gọi ở từng bước. Mô hình này giúp kiểm soát luồng xử lý tốt hơn so với việc để các tác tử giao tiếp tự do.





**Hình 3.1:** Tổng quan các mô hình tổ chức trong hệ thống đa tác tử

Như minh họa ở Hình 3.1, hệ thống đa tác tử có thể được tổ chức theo dạng mạng lưới, hội đồng, chuỗi tuần tự hoặc supervisor. Đối với bài toán sinh slide và giáo án, mô hình supervisor phù hợp vì các bước xử lý có thứ tự tương đối rõ: lập dàn ý, phát triển nội dung, bổ sung media, tạo hoạt động đánh giá, ghép kết quả và kiểm tra chất lượng.

### 3.7.2 Phạm vi áp dụng trong hệ thống

Trong đề án này, multi-agent được áp dụng rõ nhất cho pipeline sinh slide và giáo án. Toàn bộ hệ thống không phải là một hệ LangGraph multi-agent end-to-end. Ở cấp cao, request vẫn được điều phối bởi Orchestrator, ActionPlanner và ExecutionDispatcher. LangGraph chỉ điều phối content pipeline, nơi tác vụ đủ dài và có nhiều artifact trung gian cần phối hợp.

Ranh giới này quan trọng vì các chức năng như quiz standalone có trạng thái tương tác riêng, bao gồm lượt làm bài, câu trả lời của học sinh, điểm số, câu sai và thống kê tiến độ. Nếu đưa toàn bộ quiz standalone vào content multi-agent pipeline, state học tập sẽ bị trộn với state sinh artifact và khó kiểm soát hơn.

### 3.7.3 A2A-lite và Human-in-the-loop

Để các tác tử trao đổi có cấu trúc, hệ thống sử dụng một contract nội bộ dạng A2A-lite. Contract này không phải là một runtime phân tán đầy đủ, mà là cách

chuẩn hóa thông điệp trong cùng process. Một task gửi đến tác tử gồm mục tiêu, đầu vào, ràng buộc và artifact mong đợi; kết quả trả về gồm trạng thái, artifact, cảnh báo và metadata thực thi.

Human-in-the-loop được dùng trong bước duyệt dàn ý slide hoặc giáo án. Sau khi dàn ý được tạo, pipeline có thể tạm dừng để người dùng duyệt hoặc yêu cầu chỉnh sửa. Cơ chế này giúp kiểm soát cấu trúc nội dung trước khi hệ thống sinh phần chi tiết.

### 3.8 Tool layer và MCP-like protocol

Tool layer cho phép hệ thống chuẩn hóa cách các thành phần gọi công cụ bên ngoài hoặc công cụ nội bộ. Một công cụ cần có tên, mô tả, schema đầu vào và đầu ra. Khi tác tử hoặc service cần sử dụng công cụ, yêu cầu được đóng gói thành request có cấu trúc rồi dispatch đến implementation tương ứng.

Trong dự án, MCP-like protocol hiện đóng vai trò chuẩn hóa tool call nội bộ và làm điểm mở rộng. Các tool như truy xuất tri thức hoặc định dạng context có thể được bọc dưới cùng một interface. Tuy nhiên, đây chưa phải là triển khai MCP phân tán ở môi trường vận hành thực tế. Những năng lực như tìm kiếm media, kiểm tra URL hoặc gắn nguồn tham khảo là hướng phù hợp để mở rộng tool layer trong tương lai.

### 3.9 Đánh giá chất lượng hệ thống RAG

Đánh giá hệ thống RAG cần xem xét cả chất lượng truy xuất và chất lượng sinh câu trả lời. Nếu tài liệu truy xuất không đúng, câu trả lời có thể sai hoặc thiếu. Nếu tài liệu đúng nhưng mô hình sinh không bám sát tài liệu, hệ thống vẫn có thể tạo ra hallucination.

#### 3.9.1 LLM-as-a-Judge

LLM-as-a-Judge là cách dùng một mô hình ngôn ngữ làm bộ đánh giá tự động. Mô hình đánh giá có thể so sánh câu trả lời với ngữ cảnh, câu hỏi và đáp án tham chiếu để cho điểm theo một tiêu chí cụ thể. Cách tiếp cận này giúp kiểm thử trên nhiều mẫu nhanh hơn so với đánh giá thủ công hoàn toàn.

#### 3.9.2 Các thước đo RAG

Faithfulness đo mức độ các luận điểm trong câu trả lời có được hỗ trợ bởi ngữ cảnh truy xuất hay không:

$$Faithfulness = \frac{|V \cap C|}{|V|} \quad (3.7)$$

Trong đó,  $V$  là tập luận điểm rút ra từ câu trả lời, còn  $C$  là tập luận điểm có thể suy ra từ ngữ cảnh.

Answer Relevance đo mức độ câu trả lời bám sát câu hỏi. Một cách tính phổ biến là sinh ngược các câu hỏi giả định từ câu trả lời, sau đó so sánh embedding của chúng với câu hỏi gốc:

$$Answer\ Relevance = \frac{1}{N} \sum_{i=1}^N \cos(E_q, E_{g_i}) \quad (3.8)$$

Trong đó,  $E_q$  là embedding của câu hỏi gốc, còn  $E_{g_i}$  là embedding của câu hỏi giả định thứ  $i$ .

Context Recall đo mức độ ngữ cảnh truy xuất bao phủ các thông tin cần thiết trong đáp án tham chiếu:

$$Context\ Recall = \frac{|GT \cap R|}{|GT|} \quad (3.9)$$

Trong đó,  $GT$  là tập thông tin thiết yếu từ đáp án tham chiếu, còn  $R$  là tập thông tin có trong ngữ cảnh truy xuất.

Context Precision đánh giá khả năng xếp hạng các tài liệu hữu ích lên vị trí cao:

$$Context\ Precision = \frac{\sum_{k=1}^K (Precision@k \times v_k)}{\text{Tổng số tài liệu liên quan trong } K} \quad (3.10)$$

Trong đó,  $K$  là số tài liệu được xét,  $v_k = 1$  nếu tài liệu tại vị trí  $k$  có chứa thông tin liên quan và  $v_k = 0$  nếu ngược lại.

Bên cạnh các thước đo RAG, hệ thống còn cần các bước kiểm tra chất lượng ở mức ứng dụng. Với quiz standalone, câu hỏi được kiểm tra ở cấp bộ câu hỏi và từng câu hỏi trước khi lưu vào session. Với slide và giáo án, kết quả sau khi ghép artifact được đưa qua bước quality review để quyết định chấp nhận, yêu cầu sửa hoặc dừng pipeline. Các cơ chế này bổ sung cho đánh giá định lượng và giúp giảm lỗi trong luồng sử dụng thực tế.

### 3.10 Kết chương

Chương này đã trình bày các nền tảng lý thuyết và công nghệ chính được sử dụng trong hệ thống, bao gồm biểu diễn ngôn ngữ, mô hình ngôn ngữ lớn, RAG, truy xuất lai, adaptive retrieval, điều phối intent, quản lý session, multi-agent, A2A-lite, HITL, tool layer và đánh giá RAG. Các nội dung này tạo cơ sở để hiểu vì sao hệ thống không chỉ gọi trực tiếp LLM, mà cần nhiều lớp kiểm soát để bảo đảm câu

trả lời bám sát sách giáo khoa và phù hợp với từng tác vụ học tập.

Chương tiếp theo sẽ trình bày cách các nền tảng trên được hiện thực hóa trong kiến trúc hệ thống, bao gồm luồng xử lý request, các service chính, pipeline RAG, pipeline quiz, pipeline sinh slide/giáo án và kết quả đánh giá thực nghiệm.

## CHƯƠNG 4. PHÂN TÍCH THIẾT KẾ, TRIỂN KHAI VÀ ĐÁNH GIÁ HỆ THỐNG

Chương 3 đã trình bày các nền tảng công nghệ được sử dụng trong đồ án, bao gồm mô hình ngôn ngữ lớn, truy xuất tăng cường sinh, biểu diễn vector và kiến trúc đa tác tử. Trên cơ sở đó, Chương 4 mô tả hiện trạng triển khai của hệ thống và các kết quả thực nghiệm đã thu được. Nội dung chương tập trung vào môi trường thực nghiệm, kiến trúc xử lý yêu cầu, các lớp chức năng chính, quy trình đa tác tử cho slide và giáo án, cơ chế truy xuất tri thức, hậu kiểm chất lượng, quản lý phiên, và kết quả đánh giá RAGAS.

Mục tiêu của chương này là làm rõ hệ thống đã được hiện thực hóa như thế nào so với định hướng thiết kế. Các sơ đồ trong chương được trình bày theo từng lớp xử lý để thể hiện vai trò của mỗi khối trong vòng đời yêu cầu, đồng thời phân biệt rõ bộ điều phối cấp hệ thống, các dịch vụ nghiệp vụ, quy trình đa tác tử nội bộ và lớp truy xuất tri thức.

### 4.1 Môi trường và dữ liệu thực nghiệm

#### 4.1.1 Môi trường phát triển

Hệ thống được xây dựng chủ yếu bằng ngôn ngữ lập trình Python, kết hợp với các thư viện xử lý số như Numpy và Pandas để thao tác trên ma trận vector nhúng. Phần điều phối tổng thể được thiết kế theo hướng bộ điều khiển luồng mỏng; các quyết định định tuyến chính được giữ ở tầng mã nguồn để giảm độ trễ, hỗ trợ gỡ lỗi và thuận lợi cho việc theo vết. LangGraph không được sử dụng như nền tảng bao trùm toàn bộ hệ thống, mà được dùng tập trung cho bộ điều phối sinh học liệu dài, phục vụ hai tác vụ sinh slide và giáo án.

Việc sinh ngôn ngữ tự nhiên được thực hiện thông qua API Google Gemini với mô hình `gemini-2.5-flash-lite` qua thư viện `google-genai`. Đối với truy xuất ngữ nghĩa, hệ thống sử dụng mô hình nhúng `dangvantuan/vietnamese-document-embedding`, tạo vector 768 chiều cho mỗi khối dữ liệu. Giai đoạn tái xếp hạng ở cuối quy trình truy xuất được đảm nhiệm bởi mô hình Cross-Encoder `AITeamVN/Vietnamese_Reranker`. Ngoài truy xuất ngữ nghĩa, hệ thống tự xây dựng thành phần tìm kiếm từ khóa bằng Custom BM25 và hợp nhất kết quả với semantic search thông qua Reciprocal Rank Fusion (RRF).

#### 4.1.2 Dữ liệu thực nghiệm


Nguồn dữ liệu gốc được khai thác từ toàn bộ tài liệu Sách Giáo Khoa Tin học lớp 10, 11 và 12, thuộc hai bộ sách Cánh Diều và Kết Nối Tri Thức. Qua quá trình

tiền xử lý, văn bản được làm sạch và dán nhãn phân cấp từ chủ đề, bài học đến tiểu mục. Mỗi bài học trong một cuốn sách được coi là một tài liệu nguồn, sau đó được chia nhỏ theo các heading bên trong bài để giữ nguyên ranh giới của từng đơn vị kiến thức. Tổng cộng, dữ liệu được phân rã thành 2348 khối dữ liệu, mỗi khối có thông tin mô tả như bộ sách, lớp, chủ đề, tên bài, kiểu nội dung và cấp phân cấp. Cấu trúc này phục vụ trực tiếp cho truy xuất phân cấp (Hierarchical RAG) và các tác vụ sinh học liệu cần bao phủ toàn bộ bài học.

## **4.2 Tổng quan kiến trúc toàn bộ hệ thống**

Kiến trúc hiện tại của hệ thống được tổ chức quanh một trạng thái yêu cầu trung tâm. Mỗi yêu cầu người dùng đi qua các bước phân tích ngữ cảnh, nhận diện ý định, lập kế hoạch hành động, thực thi qua các dịch vụ nghiệp vụ, truy xuất tri thức khi cần, sinh kết quả, hậu kiểm chất lượng, rồi lưu trạng thái phiên và lịch sử thực thi. Thiết kế này tách rõ ba nhóm trách nhiệm: điều phối luồng chạy, xử lý nghiệp vụ, và cung cấp năng lực truy xuất/công cụ.

Sơ đồ tổng quan tại Hình 4.1 thể hiện vòng đời xử lý chính của một yêu cầu trong hệ thống.




**Hình 4.1:** Sơ đồ tổng quan kiến trúc hệ thống theo vòng đời xử lý yêu cầu

Trong kiến trúc này, bộ điều phối không đóng vai một agent tự trị toàn phần. Nó chỉ giữ trạng thái xử lý của yêu cầu, gọi mô hình ngôn ngữ ở các vị trí thật sự cần suy luận ngôn ngữ, và sử dụng mã nguồn xác định cho các bước lập kế hoạch, định tuyến, lưu phiên và ghi vết. Nhờ vậy, hệ thống vừa hỗ trợ nhiều ý định trong một yêu cầu, vừa tránh việc tạo thêm nhiều lượt gọi mô hình không cần thiết ở các bước có thể quyết định bằng logic.

### 4.3 Thiết kế chi tiết các thành phần hệ thống

#### 4.3.1 Thiết kế Lớp Ngữ cảnh và Ý định (Context & Intent Layer)

Đầu vào của hệ thống gồm câu hỏi gốc, thông tin người dùng, bộ sách/lớp được chọn từ giao diện, lịch sử phiên, các truy vấn phục vụ truy xuất tri thức và thông tin hỗ trợ theo vết. Lớp Ngữ cảnh và Ý định có nhiệm vụ làm rõ yêu cầu hiện tại trước khi hệ thống lập kế hoạch hành động.



**Hình 4.2:** Chi tiết cấu trúc và luồng xử lý tại Lớp Ngữ cảnh và Ý định

**ContextAnalyzer** được triển khai bằng logic mã nguồn để đánh giá câu hỏi hiện tại có phụ thuộc vào lịch sử hội thoại hay không. Khi cần, hệ thống trích xuất các lượt hội thoại gần và liên quan để bổ sung vào câu hỏi hiện tại.


**QueryRewriter** chỉ được gọi khi cần làm giàu truy vấn cho RAG. Thành phần này có thể tạo nhiều truy vấn ngữ nghĩa từ cùng một câu hỏi, giúp retrieval bao phủ tốt hơn những câu hỏi thiếu ngữ cảnh.

Bộ nhận diện ý định là lời gọi LLM quan trọng ở đầu quy trình. Thành phần này phân tích đồng thời nhiều ý định trong một câu hỏi và trả về danh sách ý định gồm loại yêu cầu chính, chủ đề, lớp, bộ sách và thứ tự xử lý. Giới hạn tối đa 3 ý định được dùng để tránh mở rộng trạng thái quá mức khi người dùng nhập một yêu cầu phức hợp.



### 4.3.2 Thiết kế Lớp Lập kế hoạch (Planning Layer)

Sau khi có danh sách ý định, hệ thống chuyển sang tầng lập kế hoạch hoàn toàn bằng luật. Tầng này quản lý phiên học và lập kế hoạch hành động; không sử dụng thêm LLM để quyết định hành động.




**Hình 4.3:** Chu trình lập kế hoạch hành động bằng rule-based logic

**SessionManager** kiểm tra phiên tương ứng với người dùng và chủ đề hiện tại. Thành phần này quyết định nên tiếp tục phiên đang có, khôi phục từ bộ nhớ phiên, hay tạo phiên mới.

Bộ lập kế hoạch ánh xạ mỗi ý định sang một hành động cụ thể. Các hành động chính bao gồm sinh quiz, sinh slide, sinh giáo án, chấm đáp án, ôn câu sai, thống kê tiến độ, giải thích khái niệm và chat. Khi nhiều ý định liên tiếp tạo ra cùng một hành động, bộ lập kế hoạch loại bỏ trùng lặp để tránh thực thi dư thừa.

### 4.3.3 Thiết kế Lớp Thực thi (Execution Layer)

Lớp Thực thi nhận danh sách hành động và xử lý theo vòng lặp đa tác vụ. Ở mỗi vòng, bộ điều phối chọn tác vụ đang chạy, sau đó chuyển quyền thực thi cho bộ định tuyến thực thi. Bộ định tuyến dùng danh mục nội bộ để gọi đúng dịch vụ hoặc bộ xử lý.



**Hình 4.4:** Sơ đồ vòng lặp đa tác vụ và điều phối dịch vụ nghiệp vụ


Dịch vụ quiz sở hữu toàn bộ vòng đời quiz độc lập: sinh câu hỏi, hậu kiểm chất lượng, chấm đáp án, giải thích câu hỏi, ôn câu sai, thống kê và cập nhật tiến độ học tập. Vì luồng này có nhiều trạng thái tương tác như lướt làm quiz và bản ghi từng câu hỏi, nó được giữ ở dạng dịch vụ nghiệp vụ thay vì đưa vào quy trình đa tác tử sinh học liệu.

Dịch vụ slide/giáo án là lớp mặt tiền cho cả hai tác vụ sinh slide và giáo án. Dịch vụ này truy xuất dữ liệu từ lớp tri thức, tạo đầu vào cho bộ điều phối nội dung, quản lý bước duyệt dàn ý có con người tham gia, và lưu thông tin tóm tắt để có thể tiếp tục quy trình ở lượt tương tác sau.

Các bộ xử lý giải thích, hội thoại tự do và xử lý dự phòng đảm nhiệm các nhánh hội thoại hẹp hơn. Với câu hỏi cần tri thức SGK, bộ định tuyến gọi RAG trước khi đưa ngữ cảnh vào bộ xử lý; với hội thoại tự do, hệ thống có thể bỏ qua RAG để giảm độ trễ.

#### 4.3.4 Thiết kế Quy trình Đa tác tử cho Slide và Giáo án

Hai chức năng sinh slide và sinh giáo án có cùng bản chất nghiệp vụ: cần lấy nội dung SGK liên quan, lập trình tự sự phạm, viết nội dung chi tiết, gợi ý media, sinh hoạt động đánh giá nhúng, hợp nhất kết quả trung gian và kiểm tra chất lượng. Vì vậy hệ thống dùng chung một bộ điều phối nội dung thay vì duy trì hai bộ điều phối riêng. Khác biệt giữa hai tác vụ được biểu diễn bằng loại học liệu cần sinh: slide hoặc giáo án.



**Hình 4.5:** Pipeline đa tác tử nội bộ cho sinh slide và giáo án


Giao tiếp giữa bộ điều phối và các agent chuyên trách sử dụng hợp đồng A2A-lite nội bộ. Mỗi nhiệm vụ được mô tả bằng bên gửi, bên nhận, loại nhiệm vụ, mục tiêu, dữ liệu vào, ràng buộc và kết quả kỳ vọng. Agent trả về trạng thái xử lý, kết quả trung gian, mức tin cậy, cảnh báo, danh sách công cụ đã dùng, độ trễ và lỗi nếu có. Các kết quả này được lưu trong trạng thái của quy trình qua ba nhóm dữ liệu: nhiệm vụ đã giao, kết quả agent và danh mục kết quả trung gian.

Agent lập kế hoạch sơ phạm tạo dàn ý và trình tự học tập. Agent viết nội dung tạo nội dung chi tiết cho từng slide hoặc từng mục trong giáo án dựa trên dàn ý và ngữ cảnh nguồn. Agent gợi ý media hiện đề xuất thông tin hình ảnh và tài nguyên; tìm kiếm ảnh và kiểm tra URL qua công cụ ngoài được xem là điểm mở rộng, chưa mô tả như năng lực production hoàn chỉnh. Agent đánh giá những chỉ sinh câu hỏi hoặc hoạt động đánh giá trong slide/giáo án, không thay thế dịch vụ quiz độc lập. Agent hậu kiểm chất lượng kiểm tra độ đúng sự kiện, độ bao phủ, tính sơ phạm và định dạng sau khi hợp nhất.

Thành phần hợp nhất kết quả không được xem là agent. Đây là service/tool xác định, có nhiệm vụ hợp nhất dàn ý, nội dung, media và phần đánh giá thành danh sách slide/section cuối cùng. Việc tách bước hợp nhất khỏi agent giúp hệ thống tránh gán tính tự trị cho một bước không cần suy luận LLM.

#### 4.3.5 Thiết kế Lớp Tri thức (Knowledge Layer)

Lớp Tri thức cung cấp giao diện truy xuất chính cho các thành phần nghiệp vụ. Bên trong, bộ truy xuất thích nghi sử dụng bộ phân loại truy vấn dựa trên heuristic, không gọi LLM, để chọn chiến lược truy xuất phù hợp với loại câu hỏi và phạm vi lớp/bộ sách/chủ đề.



**Hình 4.6:** Cấu trúc xử lý và truy xuất thông tin của Knowledge Layer

**STANDARD** phục vụ các truy vấn cụ thể bằng Hybrid Search: Custom BM25 và semantic search được hợp nhất qua RRF, sau đó đi qua Cross-Encoder Reranker để lấy nhóm khối dữ liệu liên quan nhất. **BROAD** dùng tra cứu thông tin mô tả trên các khối mục tiêu, phù hợp với truy vấn tổng quan. **CURRICULUM** trả danh sách bài/chủ đề đã khử trùng lặp, không cần tìm kiếm vector. **HIERARCHICAL** trước tiên tìm các khối cha ở cấp cao, sau đó tìm tiếp các khối con trong cùng bài/chủ đề.

Nếu **BROAD** hoặc **HIERARCHICAL** không tìm đủ ngữ cảnh, hệ thống có thể chuyển sang **STANDARD** để bảo vệ độ phủ. Sau truy xuất, bộ kết hợp ngữ cảnh định dạng thông tin theo loại tác vụ: các tác vụ hỏi đáp hoặc quiz ưu tiên thứ tự điểm liên quan, còn slide và giáo án nhóm ngữ cảnh theo chủ đề/bài học để giữ

mạch sư phạm.


Kiến trúc MCP trong project hiện ở dạng lớp công cụ chạy trong tiến trình, gồm thành phần quản lý client, server và danh mục công cụ. Các công cụ chính phục vụ truy xuất tri thức và định dạng nội dung. Chức năng tìm kiếm web được xem là điểm mở rộng cho media/resource search, không phải kết quả thực nghiệm chính trong chương này.

#### 4.3.6 Thiết kế Lớp Sinh phản hồi và Hậu kiểm (Generation & Validation)

Tầng sinh và hậu kiểm hiện không còn là một bộ kiểm tra chung cho mọi nhánh. Hệ thống tách rõ hai đường kiểm soát chất lượng: quiz độc lập và quy trình sinh slide/giáo án.

Ở nhánh quiz độc lập, yêu cầu của người dùng thường tạo ra một đối tượng có vòng đời tương tác dài. Câu hỏi sau khi sinh không chỉ được trả về ngay, mà còn được lưu để phục vụ chấm điểm, giải thích đáp án, ôn câu sai và thống kê tiến độ. Vì vậy nhánh này cần kiểm soát chặt chất lượng từng câu hỏi trước khi ghi vào trạng thái phiên.

Ở nhánh slide và giáo án, đầu ra là một sản phẩm tổng hợp gồm nhiều phần nội dung. Các agent chuyên trách tạo từng nhóm nội dung riêng, sau đó bước hợp nhất ghép kết quả theo một quy tắc xác định trước khi chuyển sang hậu kiểm. Agent hậu kiểm chất lượng không thay thế các agent sinh nội dung, mà chỉ đánh giá kết quả đã hợp nhất để quyết định chấp nhận, yêu cầu sửa lại hoặc chặn đầu ra lỗi nghiêm trọng.




**Hình 4.7:** Hai đường sinh và hậu kiểm chất lượng trong hệ thống

Với **quiz độc lập**, dịch vụ quiz lấy ngữ cảnh từ RAG, gọi bộ sinh tương ứng với loại câu hỏi, chạy hậu kiểm chất lượng, có thể yêu cầu sửa một lần, sau đó kiểm tra câu hỏi theo tiêu chí và nguồn tham chiếu. Chỉ những câu hỏi được phê duyệt mới được lưu vào trạng thái lượt làm quiz. Các bước chấm điểm, ôn câu sai và thống kê tiếp tục đọc từ trạng thái quiz này.

Với **slide và giáo án**, dịch vụ slide gọi bộ điều phối nội dung. Sau khi các agent chuyên trách trả kết quả, bước hợp nhất ghép các phần thành đầu ra cuối. Agent hậu kiểm đánh giá độ đúng sự kiện, độ bao phủ, tính sư phạm và định dạng. Nếu kết quả chưa đạt, bộ điều phối có thể định tuyến lại agent chịu trách nhiệm để sửa; nếu lỗi nghiêm trọng, đầu ra bị chặn thay vì trả về người dùng.

#### **4.3.7 Thiết kế Trả phản hồi, Lưu phiên và Ghi vết**

Chặng cuối của quy trình chịu trách nhiệm trả kết quả theo luồng, ghi vết thực thi và lưu trạng thái phiên. Thiết kế này giúp người dùng nhận phản hồi sớm trong khi hệ thống vẫn giữ được lịch sử đủ để tiếp tục các tác vụ tương tác như chấm bài, ôn câu sai hoặc tiếp tục quy trình sinh slide/giáo án.



**Hình 4.8:** Khối phản hồi, ghi trace và lưu trạng thái phiên

Bộ nhớ phiên lưu dữ liệu cục bộ dưới dạng JSON, cho phép hệ thống khôi phục lịch sử hội thoại, trạng thái quiz và trạng thái slide giữa các lượt tương tác. Thành phần ghi vết lưu lại đường đi của yêu cầu, bao gồm các bước thực thi phục vụ gỡ lỗi. Riêng với quy trình slide/giáo án, khi bộ điều phối nội dung dừng ở bước duyệt dàn ý, dịch vụ slide lưu thông tin tiếp tục gồm mã luồng, cấu hình luồng, cờ tạm dừng và loại học liệu để nối lại đúng quy trình sau khi người dùng gửi phản hồi.

## 4.4 Đánh giá hiệu năng và Kết quả thực nghiệm

### 4.4.1 Phương pháp đánh giá

Hệ thống sử dụng phương pháp đánh giá định lượng dành riêng cho hệ thống Retrieval-Augmented Generation (RAG) thông qua Ragas framework. Tập dữ liệu kiểm thử gồm 246 mẫu câu hỏi và đáp án tham chiếu được trích xuất từ dữ liệu giáo khoa, tập trung vào nhiều cấp độ hành vi nhận thức từ nhận biết, thông hiểu đến vận dụng.

Quá trình đánh giá được thực hiện trên 4 độ đo cốt lõi của Ragas:

**Faithfulness (Độ trung thực):** Đo lường mức độ câu trả lời của mô hình bám sát vào ngữ cảnh mà hệ thống truy xuất được. Mức điểm cao chứng tỏ mô hình không bịa đặt thông tin ngoài nguồn.

**Answer Relevancy (Độ phù hợp):** Đánh giá xem câu trả lời có giải quyết trực tiếp truy vấn ban đầu của người dùng hay không, tránh trả lời lan man hoặc sai trọng tâm.

**Context Precision (Độ chính xác ngữ cảnh):** Đánh giá khả năng xếp hạng của cụm truy xuất. Điểm số cao đồng nghĩa với việc các tài liệu liên quan nhất được xếp ở các thứ hạng đầu.

**Context Recall (Độ bao phủ ngữ cảnh):** Đo lường khả năng hệ thống tìm ra đầy đủ các thông tin cần thiết từ cơ sở tri thức so với đáp án tham chiếu.

### 4.4.2 Kết quả thực nghiệm phân hệ RAG

Sau quá trình chạy tự động 246 mẫu thử trên quy trình RAG của hệ thống, kết quả điểm số đánh giá trung bình trên các độ đo như sau:

| Chỉ số đánh giá (Metric)                         | Điểm số trung bình (Mean) |
|--------------------------------------------------|---------------------------|
| Faithfulness (Độ trung thực)                     | 0.9757                    |
| Answer Relevancy (Độ thiết thực của câu trả lời) | 0.8571                    |
| Context Precision (Độ chính xác của ngữ cảnh)    | 0.8555                    |
| Context Recall (Độ bao phủ của ngữ cảnh)         | 0.9593                    |

**Bảng 4.1:** Kết quả đánh giá hệ thống theo framework Ragas

**Phân tích kết quả:** Faithfulness đạt 0.9757 và Context Recall đạt 0.9593. Kết quả này cho thấy chiến lược Hierarchical RAG kết hợp với chunking theo phân cấp SGK đã giúp hệ thống truy xuất được phần lớn các đơn vị kiến thức cần thiết, đồng



thời hạn chế hiện tượng sinh thông tin ngoài ngữ cảnh.

**Context Precision (0.8555)** và **Answer Relevancy (0.8571)** ổn định quanh mức 85%. Kết quả này phản ánh hiệu quả của việc kết hợp BM25, semantic search, RRF và Cross-Encoder Reranker trong việc đưa các khối dữ liệu liên quan lên nhóm đầu. Khi ngữ cảnh đầu vào có độ liên quan cao hơn, lời nhắc sinh câu trả lời có cơ sở tốt hơn để bám sát trọng tâm câu hỏi.

Các tầng chất lượng trong hệ thống đóng vai trò hậu kiểm theo từng loại tác vụ. Các thành phần này không thay thế RAG, mà bổ sung thêm lớp kiểm soát để giảm rủi ro trả về nội dung sai, thiếu căn cứ hoặc không đúng định dạng.

#### 4.4.3 Đánh giá độ trễ hệ thống (Latency)

Bên cạnh chất lượng phản hồi, hệ thống còn được đo đạc về mặt thời gian thực thi nhằm đánh giá trải nghiệm người dùng thực tế. Các chỉ số thời gian được ghi nhận cho mỗi truy vấn đầy đủ như sau:

| Thành phần thực thi                   | Thời gian trung bình (Giây) |
|---------------------------------------|-----------------------------|
| Khối truy xuất (Retriever & Reranker) | 4.579                       |
| Khối sinh câu trả lời (LLM Generator) | 1.979                       |
| <b>Tổng thời gian xử lý</b>           | <b>6.558</b>                |

**Bảng 4.2:** Thống kê thời gian trễ của các khối kiến trúc trong hệ thống

Tổng thời gian cho một vòng xử lý RAG đầy đủ đạt trung bình xấp xỉ 6.5 giây. Trọng số thời gian chủ yếu nằm ở khâu truy xuất và reranking do hệ thống phải thực hiện Hybrid Search, hợp nhất kết quả và tái xếp hạng bằng Cross-Encoder. Tuy nhiên, cơ chế streaming ở tầng phản hồi giúp người dùng nhận kết quả theo từng phần thay vì phải chờ toàn bộ nội dung hoàn tất mới hiển thị.

Chương này đã trình bày hiện trạng triển khai của hệ thống trợ lý giáo dục theo vòng đời xử lý một yêu cầu. Kiến trúc hiện tại sử dụng trạng thái yêu cầu trung tâm, bộ điều phối mỏng, bộ định tuyến thực thi và các dịch vụ nghiệp vụ để xử lý từng nhóm tác vụ. Quy trình sinh slide và giáo án được tách thành một nhánh đa tác tử riêng, trong khi quiz độc lập tiếp tục được quản lý bởi dịch vụ quiz để bảo toàn các chức năng chấm điểm, ôn tập và thống kê.

Các kết quả thực nghiệm cho thấy quy trình RAG đạt điểm cao ở hai khía cạnh trung thực và bao phủ ngữ cảnh. Điều này phù hợp với mục tiêu của đề án là xây dựng một hệ thống sinh phản hồi có căn cứ từ SGK thay vì chỉ dựa vào tri thức nội tại của mô hình ngôn ngữ lớn. Những kết quả và giới hạn triển khai được trình bày

trong chương này là cơ sở để Chương 5 phân tích sâu hơn các giải pháp và đóng góp kỹ thuật của đề án.

## CHƯƠNG 5. CÁC GIẢI PHÁP VÀ ĐÓNG GÓP NỔI BẬT

Các chương trước đã trình bày nền tảng lý thuyết và kết quả triển khai của hệ thống. Chương này tập trung phân tích các giải pháp và đóng góp nổi bật của đề án dưới góc nhìn thiết kế kỹ thuật. Trọng tâm không nằm ở việc liệt kê lại từng module, mà làm rõ các vấn đề khó đã gặp phải trong quá trình xây dựng trợ lý giáo dục dựa trên LLM và cách hệ thống giải quyết các vấn đề đó bằng kiến trúc có thể kiểm soát, dễ mở rộng và phù hợp với dữ liệu sách giáo khoa.

Các đóng góp chính gồm thiết kế điều phối request ở mức mã nguồn, cơ chế truy xuất thích nghi, nhận diện đa ý định, tách biệt pipeline quiz tương tác khỏi pipeline sinh nội dung dài, tổ chức content multi-agent cho slide và giáo án, chuẩn hóa giao tiếp nội bộ giữa các agent bằng A2A-lite, bổ sung HITL tại điểm quyết định quan trọng, và xây dựng các lớp kiểm tra chất lượng, session, trace phục vụ vận hành.

### 5.1 Điều phối request bằng thin orchestrator

#### 5.1.1 Vấn đề cần giải quyết

Một hệ thống trợ lý giáo dục không chỉ nhận câu hỏi và gọi LLM để trả lời. Cùng một giao diện chat phải xử lý nhiều nhóm tác vụ khác nhau như hỏi đáp kiến thức, sinh câu hỏi luyện tập, chấm câu trả lời, ôn lại câu sai, tạo slide, tạo giáo án hoặc tiếp tục một pipeline đang chờ người dùng duyệt. Nếu đưa toàn bộ luồng xử lý vào một prompt lớn hoặc một agent tự quyết định mọi bước, hệ thống sẽ khó kiểm soát, khó gỡ lỗi và dễ gọi sai chức năng.

Vấn đề phức tạp hơn khi mỗi request cần mang theo nhiều loại trạng thái. Một câu hỏi có thể phụ thuộc lịch sử hội thoại, phạm vi sách/lớp người dùng chọn, chủ đề đã học trước đó, quiz state hoặc slide state đang chờ resume. Vì vậy, hệ thống cần một lớp điều phối rõ ràng để tách phần hiểu ngôn ngữ tự nhiên khỏi phần thực thi nghiệp vụ.

#### 5.1.2 Giải pháp

Đề án thiết kế Orchestrator theo hướng thin controller. Orchestrator không chứa trực tiếp logic sinh câu hỏi, truy xuất tài liệu hoặc sinh slide, mà chủ yếu tạo `RequestContext`, phân tích ngữ cảnh, gọi `IntentRouter`, lập action plan và chuyển quyền thực thi cho `ExecutionDispatcher`. Cách làm này giữ Orchestrator ở vai trò điều phối, còn nghiệp vụ chi tiết được đóng gói trong các domain service hoặc handler.

`RequestContext` là state object đi xuyên qua toàn bộ vòng đời request. Nó lưu câu hỏi gốc, truy vấn đã làm giàu, danh sách query dùng cho RAG, intent,

action plan, phạm vi sách/lớp, session và debug steps. Nhờ đó, các module không cần truyền nhiều biến rời rạc hoặc phụ thuộc vào global state. Khi cần kiểm tra một lỗi, hệ thống có thể nhìn lại từng bước request đã đi qua.

Một điểm quan trọng là `ActionPlanner` hoạt động bằng rule-based logic thay vì gọi thêm LLM. LLM chỉ được dùng ở bước cần hiểu ngôn ngữ tự nhiên, còn ánh xạ từ intent sang action được giữ bằng mã nguồn tường minh. Điều này giảm độ trễ, tránh phát sinh nhánh xử lý ngoài kiểm soát và giúp việc thêm action mới có điểm mở rộng rõ ràng.

### 5.1.3 Đóng góp đạt được

Thiết kế này giải quyết được mâu thuẫn giữa tính linh hoạt của giao diện hội thoại và yêu cầu kiểm soát của hệ thống giáo dục. Người dùng vẫn có thể nhập yêu cầu tự nhiên, nhưng hệ thống không giao toàn bộ quyền điều phối cho LLM. Mỗi action được dispatch đến đúng service phụ trách, giúp kiến trúc dễ mở rộng hơn khi bổ sung chức năng mới.

Thin orchestrator cũng tạo nền tảng cho trace và debug. Mỗi request có request id, timestamp, debug steps và thông tin strategy RAG đã chọn. Đây là đóng góp thực tế quan trọng vì hệ thống LLM thường khó quan sát nếu chỉ nhìn đầu vào và đầu ra cuối cùng.

## 5.2 Truy xuất lại và Adaptive RAG

### 5.2.1 Vấn đề cần giải quyết

Dữ liệu sách giáo khoa có đặc điểm khác với dữ liệu web mở. Nhiều khái niệm quan trọng được trình bày ngắn gọn, có thuật ngữ chuyên ngành, tên lệnh, tên bài học hoặc cấu trúc chương mục rõ ràng. Nếu chỉ dùng tìm kiếm ngữ nghĩa, hệ thống có thể bỏ sót các đoạn có từ khóa chính xác. Nếu chỉ dùng tìm kiếm từ khóa, hệ thống khó xử lý câu hỏi diễn đạt tự nhiên khác với văn bản trong sách.

Ngoài ra, không phải câu hỏi nào cũng cần cùng một cách truy xuất. Câu hỏi “giải thích khái niệm cơ sở dữ liệu” cần đoạn nội dung chi tiết, trong khi câu hỏi “lớp 12 có những chủ đề nào” cần tổng hợp cấu trúc chương trình. Một pipeline RAG cố định dễ hoặc lấy thiếu ngữ cảnh, hoặc tốn chi phí không cần thiết.

### 5.2.2 Giải pháp

Hệ thống sử dụng truy xuất lai gồm tìm kiếm từ khóa BM25-like, tìm kiếm ngữ nghĩa bằng embedding tiếng Việt, hợp nhất thứ hạng bằng RRF và xếp hạng lại bằng reranker. BM25 giúp giữ độ nhạy với thuật ngữ chính xác, còn embedding giúp bắt được các câu hỏi diễn đạt theo cách tự nhiên. RRF được dùng để hợp nhất hai danh sách kết quả mà không yêu cầu điểm số của chúng nằm trên cùng một

thang đo.

Trên lớp truy xuất cơ sở, đồ án xây dựng `AdaptiveRAGAgent`. Thành phần này chọn strategy dựa trên `QueryClassifier` heuristic, không dùng LLM để ra quyết định. Bốn strategy chính gồm STANDARD, BROAD, CURRICULUM và HIERARCHICAL. STANDARD dùng cho truy vấn cụ thể nhưng thiếu phạm vi rõ. BROAD dùng cho câu hỏi tổng quan. CURRICULUM ưu tiên metadata chương trình học. HIERARCHICAL dùng khi có đủ tín hiệu lớp/chủ đề để truy xuất theo cấp bài học rồi mới đi vào chunk chi tiết.

Hệ thống còn bổ sung scope fallback. Khi phạm vi sách/lớp chỉ đến từ UI và không đủ chunk phù hợp, `RAGService` có thể mở rộng phạm vi tìm kiếm, đồng thời ghi lại `actual_scope`, `scope_fallback_notice` và debug step tương ứng. Nhờ vậy, hệ thống không trả lời trống quá sớm nhưng vẫn minh bạch về phạm vi dữ liệu đã dùng.

### 5.2.3 Đóng góp đạt được

Đóng góp ở đây không chỉ là ghép nhiều kỹ thuật retrieval, mà là đặt chúng trong một cơ chế chọn strategy theo loại câu hỏi. Cách làm này phù hợp với bài toán giáo dục vì câu hỏi của học sinh và giáo viên có mức độ cụ thể rất khác nhau. Adaptive RAG giúp hệ thống cân bằng giữa độ chính xác, độ bao phủ và chi phí truy xuất.

Việc `QueryClassifier` là heuristic cũng là một quyết định có chủ đích. Thay vì gọi LLM thêm một lượt để chọn chiến lược truy xuất, hệ thống giữ bước này nhanh, có thể kiểm thử và có thể giải thích. Đây là điểm quan trọng trong một hệ thống cần ổn định hơn là thể hiện khả năng suy luận tự do.

## 5.3 Multi-intent routing và action planning

### 5.3.1 Vấn đề cần giải quyết

Trong giao diện hội thoại, người dùng không luôn đưa ra một yêu cầu đơn lẻ. Một câu có thể chứa nhiều ý định, ví dụ yêu cầu tạo slide rồi thêm câu hỏi luyện tập, hoặc vừa giải thích kiến thức vừa sinh bài tập. Nếu hệ thống chỉ chọn một intent duy nhất, một phần yêu cầu sẽ bị bỏ qua. Ngược lại, nếu để LLM tự thực thi toàn bộ chuỗi hành động, hệ thống dễ sinh ra luồng không nhất quán với các service đang có.

### 5.3.2 Giải pháp

`IntentRouter.detect_multi()` phân tích tối đa ba intent trong một câu hỏi. Mỗi intent gồm nhóm ý định chính, loại nhiệm vụ, chủ đề, lớp, bộ sách và một số metadata cần thiết. Sau đó, `ActionPlanner.plan_all()` chuyển danh

sách intent thành danh sách action cụ thể như sinh quiz, sinh slide, sinh giáo án, chấm câu trả lời, ôn câu sai hoặc giải thích khái niệm.

Việc giới hạn số intent là một quyết định thực tế. Nó đủ để xử lý các câu lệnh ghép thường gặp, nhưng tránh để một câu nhập mơ hồ sinh ra quá nhiều action và làm phình state. Sau bước lập kế hoạch, `ExecutionDispatcher` chịu trách nhiệm gọi đúng service hoặc handler theo action đã xác định.

### 5.3.3 Đóng góp đạt được

Cơ chế này giúp hệ thống xử lý yêu cầu tự nhiên tốt hơn mà vẫn giữ được tính quyết định của backend. LLM được dùng để hiểu câu nói của người dùng, nhưng kế hoạch thực thi cuối cùng được đưa về cấu trúc action rõ ràng. Điều này tạo ra một ranh giới cần thiết giữa năng lực ngôn ngữ của LLM và logic nghiệp vụ của phần mềm.

## 5.4 Tách quiz standalone khỏi content assessment

### 5.4.1 Vấn đề cần giải quyết

Sinh câu hỏi luyện tập có thể xuất hiện trong hai bối cảnh khác nhau. Bối cảnh thứ nhất là quiz standalone, nơi người dùng tạo bộ câu hỏi, trả lời, được chấm điểm, xem lại câu sai và theo dõi tiến độ. Bối cảnh thứ hai là assessment nhúng trong slide hoặc giáo án, nơi câu hỏi chỉ là một artifact phụ để củng cố bài giảng.

Nếu gộp hai bối cảnh này vào cùng một agent hoặc cùng một pipeline, hệ thống sẽ khó quản lý state. Quiz standalone cần lưu từng lượt làm bài, từng câu hỏi, câu trả lời của người dùng, số lần thử và kết quả chấm. Assessment trong slide lại chủ yếu cần nội dung phù hợp với bài học và format trình bày.

### 5.4.2 Giải pháp

Đề án giữ `QuizService` là một service độc lập cho quiz tương tác. Service này quản lý vòng đời sinh câu hỏi, kiểm tra chất lượng, lưu `QuizRound`, lưu `QuestionRecord`, chấm câu trả lời, review câu sai và thống kê tiến độ. Các handler câu hỏi như trắc nghiệm, tự luận, điền khuyết và đúng/sai được giữ trong pipeline quiz riêng.

Trong content multi-agent pipeline, `ContentAssessmentAgent` chỉ sinh assessment nhúng cho slide hoặc giáo án. Agent này không thay thế `QuizService` và không quản lý state làm bài của học sinh. Cách tách này giúp tránh nhầm lẫn giữa một bài kiểm tra tương tác và một phần hoạt động trong tài liệu giảng dạy.

### 5.4.3 Đóng góp đạt được

Đây là một đóng góp kiến trúc quan trọng vì nó giữ đúng ranh giới nghiệp vụ. Quiz standalone có thể phát triển thêm các chức năng học tập cá nhân hóa mà không ảnh hưởng đến pipeline sinh slide. Ngược lại, pipeline sinh slide/giáo án có thể tối ưu cho artifact dài mà không phải mang theo toàn bộ logic chấm điểm và theo dõi attempt.

## 5.5 Content multi-agent cho slide và giáo án

### 5.5.1 Vấn đề cần giải quyết

Tạo slide và giáo án là tác vụ dài hơn nhiều so với hỏi đáp hoặc sinh một bộ câu hỏi ngắn. Hệ thống phải xác định mục tiêu học tập, lập dàn ý, viết nội dung chi tiết, gợi ý media, thêm assessment, ghép kết quả và kiểm tra chất lượng. Nếu giao toàn bộ tác vụ này cho một prompt duy nhất, đầu ra dễ thiếu cấu trúc, bỏ sót phần quan trọng hoặc khó sửa khi người dùng muốn thay đổi dàn ý.

### 5.5.2 Giải pháp

Đồ án dùng LangGraph cho phạm vi content pipeline của slide và giáo án. Ở cấp hệ thống, Orchestrator vẫn là controller mã nguồn; LangGraph chỉ điều phối luồng sinh nội dung dài. ContentSupervisor gọi các tool adapter tương ứng với các specialist agent như PedagogyPlannerAgent, ContentDraftingAgent, MediaResearchAgent, ContentAssessmentAgent và QualityReviewerAgent.

Các agent không trao đổi tự do mà đi qua contract A2A-lite. Supervisor tạo AgentTask, specialist agent trả AgentTaskResult. Task chứa mục tiêu, đầu vào, ràng buộc, context refs và artifact mong đợi. Kết quả chứa trạng thái, artifact, confidence, warnings, used tools và latency. Contract này giúp mỗi kết quả trung gian có chủ sở hữu rõ ràng và dễ ghi debug.

Sau khi các artifact được tạo, merge\_results ghép outline, content, media và assessment thành kết quả thống nhất. Thành phần merge là service/tool quyết định, không phải agent. Sau đó, QualityReviewerAgent đánh giá kết quả cuối và reflection\_decision\_node quyết định approve, revise hoặc block theo số vòng reflection cho phép.

### 5.5.3 Đóng góp đạt được

Đóng góp chính của phần này là tổ chức tác vụ sinh nội dung dài thành các bước có artifact rõ ràng. Hệ thống không chỉ sinh một đoạn văn lớn, mà có dàn ý, nội dung, media metadata, assessment và review. Điều này giúp slide và giáo án dễ kiểm soát hơn, đồng thời chuẩn bị nền tảng để sau này xuất sang PPTX, PDF hoặc

HTML.

A2A-lite cũng là một lựa chọn phù hợp với quy mô hiện tại. Hệ thống chưa cần runtime distributed agent đầy đủ, nhưng đã có message envelope đủ rõ để quản lý task, artifact và metadata thực thi. Cách làm này giảm độ phức tạp vận hành nhưng vẫn giữ đường nâng cấp trong tương lai.

## **5.6 Human-in-the-loop tại bước duyệt dàn ý**

### **5.6.1 Vấn đề cần giải quyết**

Trong sinh slide và giáo án, dàn ý là quyết định ảnh hưởng đến toàn bộ artifact phía sau. Nếu dàn ý sai trọng tâm, thiếu mục hoặc chia bài không hợp lý, các bước sinh nội dung, media và assessment sau đó đều bị ảnh hưởng. Sửa ở cuối pipeline thường tốn chi phí hơn nhiều so với sửa ngay sau khi có outline.

### **5.6.2 Giải pháp**

Hệ thống đặt HITL tại bước outline review. Sau khi agent lập dàn ý, graph có thể interrupt để người dùng duyệt hoặc gửi feedback chỉnh sửa. SlideService lưu các thông tin resume như thread id, graph config, trạng thái interrupt và task type vào slide state. Khi người dùng xác nhận hoặc góp ý, pipeline resume từ điểm đã dừng thay vì chạy lại toàn bộ request từ đầu.

### **5.6.3 Đóng góp đạt được**

HITL giúp đưa quyền kiểm soát vào đúng điểm có ảnh hưởng lớn nhất. Người dùng, đặc biệt là giáo viên, có thể điều chỉnh cấu trúc bài giảng trước khi hệ thống sinh nội dung chi tiết. Cách làm này phù hợp với đặc thù giáo dục, nơi người dùng thường muốn kiểm soát mục tiêu và mạch bài học thay vì chỉ nhận một kết quả hoàn chỉnh.

## **5.7 Quality path, session và trace**

### **5.7.1 Vấn đề cần giải quyết**

Một hệ thống LLM phục vụ giáo dục cần nhiều lớp kiểm soát hơn một chatbot thông thường. Câu hỏi sinh ra cần đúng format và bám ngữ cảnh. Câu trả lời cần lưu được theo phiên để người dùng hỏi tiếp. Các lỗi cần có trace để biết hệ thống đã chọn intent, action và strategy RAG nào.

### **5.7.2 Giải pháp**

Đồ án xây dựng hai quality path riêng. Với quiz standalone, QualityReviewer kiểm tra chất lượng bộ câu hỏi và QuestionValidator kiểm tra từng câu hỏi trước khi lưu vào session. Nếu cần, handler có thể được gọi lại với revision instruction. Với slide và giáo án, kết quả sau merge được đưa qua QualityRe-



`viewerAgent`; graph có thể approve, revise một phần hoặc block nếu chất lượng chưa đạt.

Session được lưu bằng `SessionStore` dưới dạng JSON. Session không chỉ lưu lịch sử chat mà còn lưu quiz state và slide state, cho phép các yêu cầu nối tiếp như “chấm câu 2”, “ôn câu sai” hoặc “ok, duyệt dần ý”. Song song với session, `TraceService` và `RequestContext.add_debug_step()` ghi lại các bước xử lý quan trọng để hỗ trợ kiểm thử và gỡ lỗi.

### 5.7.3 Đóng góp đạt được

Các lớp quality, session và trace làm cho hệ thống có khả năng vận hành thực tế hơn. Hệ thống không chỉ tạo được câu trả lời, mà còn quản lý được vòng đời học tập của người dùng và cung cấp dữ liệu quan sát khi kết quả chưa đạt kỳ vọng. Đây là nền tảng cần thiết để tiếp tục cải thiện chất lượng truy xuất, đánh giá và cá nhân hóa trong các phiên bản sau.

## 5.8 Tool layer như điểm mở rộng có kiểm soát

### 5.8.1 Vấn đề cần giải quyết

Một số năng lực của hệ thống không nên được nhúng trực tiếp vào prompt hoặc agent, ví dụ truy xuất tri thức, định dạng context, tìm kiếm media, kiểm tra URL hoặc xuất artifact. Nếu mỗi nơi gọi tool theo một kiểu riêng, hệ thống sẽ khó mở rộng và khó thay thế implementation.

### 5.8.2 Giải pháp

Đồ án xây dựng một MCP-like tool layer in-process. Lớp này gồm protocol request/response, client, server và registry tool. Các tool như knowledge retrieval hoặc content formatting có thể được gọi qua interface thống nhất. Hiện tại, lớp này chủ yếu đóng vai trò chuẩn hóa tool call nội bộ và làm extension point; chưa được mô tả như một MCP phân tán hoàn chỉnh.

### 5.8.3 Đóng góp đạt được

Tool layer giúp tách phần năng lực mở rộng khỏi core orchestration. Khi cần bổ sung media search thật, URL validation, source attribution hoặc export artifact, hệ thống đã có vị trí phù hợp để tích hợp mà không làm thay đổi sâu các service hiện có. Đây là một đóng góp về khả năng mở rộng hơn là một tính năng hoàn chỉnh ở thời điểm hiện tại.

## 5.9 Kết chương

Chương này đã hệ thống hóa các giải pháp và đóng góp chính của đồ án. Các đóng góp không nằm ở một thuật toán riêng lẻ, mà ở cách kết hợp LLM với các lớp điều phối, truy xuất, kiểm tra chất lượng, quản lý trạng thái và quan sát hệ thống.

Thiết kế này giúp Educational Chatbot tránh phụ thuộc hoàn toàn vào khả năng sinh tự do của LLM, đồng thời giữ được tính mở rộng cho các chức năng giáo dục như quiz, slide và giáo án.

Những đóng góp trên cũng cho thấy các khó khăn chính của đề tài đã được xử lý theo hướng thực dụng: truy xuất phải thích nghi với loại câu hỏi, điều phối phải kiểm soát được nhiều intent, quiz tương tác phải tách khỏi artifact generation, multi-agent phải có contract rõ ràng, và người dùng cần được đưa vào vòng duyệt ở các điểm quyết định quan trọng.

## **CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN**

### **6.1 Kết luận**

Sinh viên so sánh kết quả nghiên cứu hoặc sản phẩm của mình với các nghiên cứu hoặc sản phẩm tương tự.

Sinh viên phân tích trong suốt quá trình thực hiện ĐATN, mình đã làm được gì, chưa làm được gì, các đóng góp nổi bật là gì, và tổng hợp những bài học kinh nghiệm rút ra nếu có.

### **6.2 Hướng phát triển**

Trong phần này, sinh viên trình bày định hướng công việc trong tương lai để hoàn thiện sản phẩm hoặc nghiên cứu của mình.

Trước tiên, sinh viên trình bày các công việc cần thiết để hoàn thiện các chức năng/nhiệm vụ đã làm. Sau đó sinh viên phân tích các hướng đi mới cho phép cải thiện và nâng cấp các chức năng/nhiệm vụ đã làm.

## MỘT SỐ LƯU Ý VỀ TÀI LIỆU THAM KHẢO

Lưu ý: Sinh viên không được đưa bài giảng/slide, các trang Wikipedia, hoặc các trang web thông thường làm tài liệu tham khảo.

Một trang web được phép dùng làm tài liệu tham khảo **chỉ khi** nó là công bố chính thống của cá nhân hoặc tổ chức nào đó. Ví dụ, trang web đặc tả ngôn ngữ XML của tổ chức W3C <https://www.w3.org/TR/2008/REC-xml-20081126/> là TLTK hợp lệ.

Có năm loại tài liệu tham khảo mà sinh viên phải tuân thủ đúng quy định về cách thức liệt kê thông tin như sau. Lưu ý: các phần văn bản trong cặp dấu < > dưới đây chỉ là hướng dẫn khai báo cho từng loại tài liệu tham khảo; sinh viên cần xóa các phần văn bản này trong ĐATN của mình.

<**Bài báo đăng trên tạp chí khoa học:** Tên tác giả, tên bài báo, tên tạp chí, volume, từ trang đến trang (nếu có), nhà xuất bản, năm xuất bản >

[1] E. H. Hovy, "Automated discourse generation using discourse structure relations," *Artificial intelligence*, vol. 63, no. 1-2, pp. 341–385, 1993

<**Sách:** Tên tác giả, tên sách, volume (nếu có), lần tái bản (nếu có), nhà xuất bản, năm xuất bản>

[2] L. L. Peterson and B. S. Davie, *Computer networks: a systems approach*. Elsevier, 2007.

[3] N. T. Hải, *Mạng máy tính và các hệ thống mở*. Nhà xuất bản giáo dục, 1999.

<**Tập san Báo cáo Hội nghị Khoa học:** Tên tác giả, tên báo cáo, tên hội nghị, ngày (nếu có), địa điểm hội nghị, năm xuất bản>

[4] M. Poesio and B. Di Eugenio, "Discourse structure and anaphoric accessibility," in *ESSLLI workshop on information structure, discourse structure and discourse semantics*, Copenhagen, Denmark, 2001, pp. 129–143.

<**Đồ án tốt nghiệp, Luận văn Thạc sĩ, Tiến sĩ:** Tên tác giả, tên đồ án/luận văn, loại đồ án/luận văn, tên trường, địa điểm, năm xuất bản>

[5] A. Knott, "A data-driven methodology for motivating a set of coherence relations," Ph.D. dissertation, The University of Edinburgh, UK, 1996.

<**Tài liệu tham khảo từ Internet:** Tên tác giả (nếu có), tựa đề, cơ quan (nếu có), địa chỉ trang web, thời gian lần cuối truy cập trang web>

[6] T. Berners-Lee, *Hypertext transfer protocol (HTTP)*. [Online]. Available:

`ftp://info.cern.ch/pub/www/doc/http-spec.txt.Z` (visited on 09/30/2010).

[7] Princeton University, *Wordnet*. [Online]. Available: `http://www.cogsci.princeton.edu/~wn/index.shtml` (visited on 09/30/2010).

## TÀI LIỆU THAM KHẢO

- [1] E. H. Hovy, “Automated discourse generation using discourse structure relations,” *Artificial intelligence*, vol. 63, no. 1-2, pp. 341–385, 1993.
- [2] L. L. Peterson and B. S. Davie, *Computer networks: a systems approach*. Elsevier, 2007.
- [3] N. T. Hải, *Mạng máy tính và các hệ thống mở*. Nhà xuất bản giáo dục, 1999.
- [4] M. Poesio and B. Di Eugenio, “Discourse structure and anaphoric accessibility,” in *ESSLLI workshop on information structure, discourse structure and discourse semantics, Copenhagen, Denmark*, 2001, pp. 129–143.
- [5] A. Knott, “A data-driven methodology for motivating a set of coherence relations,” Ph.D. dissertation, The University of Edinburgh, UK, 1996.
- [6] T. Berners-Lee, *Hypertext transfer protocol (HTTP)*. Accessed: Sep. 30, 2010. [Online]. Available: <ftp://info.cern.ch/pub/www/doc/http-spec.txt.Z>.
- [7] Princeton University, *Wordnet*. Accessed: Sep. 30, 2010. [Online]. Available: <http://www.cogsci.princeton.edu/~wn/index.shtml>.

# PHỤ LỤC

## A. HƯỚNG DẪN VIẾT ĐỒ ÁN TỐT NGHIỆP

### Quy định chung

Dưới đây là một số quy định và hướng dẫn viết đồ án tốt nghiệp mà bắt buộc sinh viên phải đọc kỹ và tuân thủ nghiêm ngặt.

Sinh viên cần đảm bảo tính thống nhất toàn báo cáo (font chữ, căn dòng hai bên, hình ảnh, bảng, margin trang, đánh số trang, v.v.). Để làm được như vậy, sinh viên chỉ cần sử dụng các định dạng theo đúng template DATN này. Khi paste nội dung văn bản từ tài liệu khác của mình, sinh viên cần chọn kiểu Copy là “Text Only” để định dạng văn bản của template không bị phá vỡ/vi phạm.

Tuyệt đối cấm sinh viên đạo văn. Sinh viên cần ghi rõ nguồn cho tất cả những gì không tự mình viết/vẽ lên, bao gồm các câu trích dẫn, các hình ảnh, bảng biểu, v.v. Khi bị phát hiện, sinh viên sẽ không được phép bảo vệ DATN.

Tất cả các hình vẽ, bảng biểu, công thức, và tài liệu tham khảo trong DATN nhất thiết phải được SV giải thích và tham chiếu tới ít nhất một lần. Không chấp nhận các trường hợp sinh viên đưa ra hình ảnh, bảng biểu tùy hứng và không có lời mô tả/giải thích nào.

Sinh viên tuyệt đối không trình bày DATN theo kiểu viết ý hoặc gạch đầu dòng. DATN không phải là một slide thuyết trình; khi người đọc không hiểu sẽ không có ai giải thích hộ. Sinh viên cần viết thành các đoạn văn và phân tích, diễn giải đầy đủ, rõ ràng. Câu văn cần đúng ngữ pháp, đầy đủ chủ ngữ, vị ngữ và các thành phần câu. Khi thực sự cần liệt kê, sinh viên nên liệt kê theo phong cách khoa học với các ký tự La Mã. Ví dụ, nhiều sinh viên luôn cảm thấy hối hận vì (i) chưa cố gắng hết mình, (ii) chưa sắp xếp thời gian học/chơi một cách hợp lý, (iii) chưa tìm được người yêu để chia sẻ quãng đời sinh viên vất vả, và (iv) viết DATN một cách cẩu thả.

Trong một số trường hợp nhất thiết phải dùng các bullet để liệt kê, sinh viên cần thống nhất Style cho toàn bộ các bullet các cấp mà mình sử dụng đến trong báo cáo. Nếu dùng bullet cấp 1 là hình tròn đen, toàn bộ báo cáo cần thống nhất cách dùng như vậy; ví dụ như sau:

- Đây là mục 1 – Thực sự không còn cách nào khác tôi mới dùng đến việc bullet trong báo cáo.
- Đây là mục 2 – Nghĩ lại thì tôi có thể không cần dùng bullet cũng được. Nên tôi sẽ xóa bullet và tổ chức lại hai mục này trong báo cáo của mình cho khoa



học hơn. Tôi muốn thầy cô và người đọc cảm nhận được tâm huyết của tôi trong từng trang báo cáo DATN.

### A.1 Ngành học

Sinh viên lưu ý viết đúng ngành/chuyên ngành trên bìa và trên gáy theo đúng quy định của Trường. Ngành học hay chuyên ngành học phụ thuộc vào ngành học mà sinh viên đăng ký. Sinh viên có thể đăng nhập trên trang quản lý học tập của mình để xem lại chính xác ngành học của mình.

Một số ví dụ sinh viên có thể tham khảo dưới đây, trong trường hợp có chuyên ngành thì sinh viên không cần ghi chuyên ngành:

1. Đối với kỹ sư chính quy:
  - (a) Từ K61 trở về trước: Ngành Kỹ thuật phần mềm
  - (b) Từ K62 trở về sau: Ngành Khoa học máy tính
2. Đối với cử nhân:
  - (a) Ngành Công nghệ thông tin
3. Đối với chương trình EliteTech:
  - (a) Chương trình Việt Nhật/KSTN: Ngành Công nghệ thông tin
  - (b) Chương trình ICT Global: Ngành Information Technology
  - (c) Chương trình DS&AI: Ngành Khoa học dữ liệu


### A.2 Đánh dấu (bullet) và đánh số (numering)

Việc sử dụng danh sách trong LaTeX khá đơn giản và không yêu cầu sinh viên phải thêm bất kỳ gói bổ sung nào. LaTeX cung cấp hai môi trường liệt kê đó là:

- Đánh dấu (bullet) là kiểu liệt kê không có thứ tự. Để sử dụng kiểu liệt kê đánh dấu, chúng ta khai báo như sau

```
\begin{itemize}
\item Nội dung thứ nhất được viết ở đây.
\item Nội dung thứ hai được viết ở đây.
\item ...
\end{itemize}
```
- Đánh số (numering) là kiểu liệt kê có thứ tự. Để sử dụng kiểu liệt kê đánh số, chúng ta khai báo như sau

```
\begin{enumerate}
\item Nội dung thứ nhất được viết ở đây.
\item Nội dung thứ hai được viết ở đây.
```



**Hình A.1:** Internet vạn vật

```
\item ...
\end{enumerate}
```

Chú ý các nội dung trình bày trong cả hai môi trường liệt kê theo sau lệnh `\item`. Ngoài ra LaTeX còn cung cấp một số kiểu liệt kê khác, sinh viên có thể tham khảo tại <https://www.overleaf.com/learn/latex/Lists>

### A.3 Cách thêm bảng

| Col1 | Col2 | Col2  | Col3 |
|------|------|-------|------|
| 1    | 6    | 87837 | 787  |
| 2    | 7    | 78    | 5415 |
| 3    | 545  | 778   | 7507 |
| 4    | 545  | 18744 | 7560 |
| 5    | 88   | 788   | 6344 |

**Bảng A.1:** Table to test captions and labels.

Bảng A.1 là ví dụ về cách tạo bảng. Tất cả các bảng biểu phải được đề cập đến trong phần nội dung và phải được phân tích và bình luận. Chú ý: Tạo bảng trong LaTeX khá phức tạp và mất thời gian, vì vậy sinh viên có thể sử dụng các công cụ hỗ trợ tạo bảng (Ví dụ: <https://www.tablesgenerator.com/>). Sinh viên có thể tìm hiểu sâu hơn về cách chèn ảnh trong LaTeX tại link <https://www.overleaf.com/learn/latex/Tables>.

### A.4 Chèn hình ảnh

Hình A.1 là ví dụ về cách chèn ảnh. Lưu ý chú thích của hình vẽ được đặt ngay dưới hình vẽ. Sinh viên có thể tìm hiểu sâu hơn về cách chèn ảnh trong LaTeX tại [https://www.overleaf.com/learn/latex/Inserting\\_Images](https://www.overleaf.com/learn/latex/Inserting_Images).

Chú ý, tất cả các hình vẽ phải được đề cập đến trong phần nội dung và phải được phân tích và bình luận.

## A.5 Tài liệu tham khảo

### Cách liệt kê

Áp dụng cách liệt kê theo quy định của IEEE. Ví dụ của việc trích dẫn như sau [2]. Cụ thể, sinh viên sử dụng lệnh `\cite{}` như sau [3]. Chỉ những tài liệu được trích dẫn thì mới xuất hiện trong phần Tài liệu tham khảo. Tài liệu tham khảo cần có nguồn gốc rõ ràng và phải từ nguồn đáng tin cậy. Hạn chế trích dẫn tài liệu tham khảo từ các website, từ wikipedia.

### Các loại tài liệu tham khảo

Các nguồn tài liệu tham khảo chính là sách, bài báo trong các tạp chí, bài báo trong các hội nghị khoa học và các tài liệu tham khảo khác trên internet.

## A.6 Cách viết phương trình và công thức toán học

Các gói `amsmath`, `amssymb`, `amsfonts` hỗ trợ viết phương trình/công thức toán học đã được bổ sung sẵn ở phần đầu của file `main.tex`. Một ví dụ về tạo phương trình (A.1) như sau

$$F(x) = \int_b^a \frac{1}{3}x^3 \quad (\text{A.1})$$

Phương trình A.1 là ví dụ về phương trình tích phân. Một phương trình khác không được đánh số thứ tự (gán nhãn)

$$x[t_n] = \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} X[f_k] e^{j2\pi nk/N}$$

Phương trình này thể hiện phép biến đổi Fourier rời rạc ngược (IDFT).

## A.7 Qui cách đóng quyển


Phần bìa trước chế bản theo qui định; bìa trước và bìa sau là giấy liền khổ. Sử dụng keo nhiệt để dán gáy khi đóng quyển thay vì sử dụng băng dính và dập ghim như mô tả ở Hình A.3 Phần gáy ĐATN cần ghi các thông tin tóm tắt sau: Kỳ làm ĐATN - Ngành đào tạo - Họ và tên sinh viên - Mã số sinh viên. Ví dụ:

2022.1 - KỸ THUẬT MÁY TÍNH - NGUYỄN VĂN A - 20221234

Qui cách ghi chữ phần gáy như hình dưới đây:



**Hình A.2:** Qui cách đóng quyển đồ án



**Hình A.3:** Qui cách đóng quyển đồ án

## **B. ĐẶC TẢ USE CASE**

Nếu trong nội dung chính không đủ không gian cho các use case khác (ngoài các use case nghiệp vụ chính) thì đặc tả thêm cho các use case đó ở đây.

### **B.1 Đặc tả use case “Tổng kê tình hình mượn sách”**

...

### **B.2 Đặc tả use case “Đăng ký làm thẻ mượn”**

...